

UNIVERSIDAD NACIONAL
AUTÓNOMA DE MÉXICO

FACULTAD DE ESTUDIOS SUPERIORES
ACATLÁN

Diplomado Ciencia de Datos

Análisis Predictivo de la Calidad del Sueño

PRESENTA

Pérez Mendoza Erick

7 de abril de 2025

Índice general

1. Introducción	2
2. Descripción de los datos	4
2.1. Calidad de los datos	4
2.2. Pretratamiento	5
3. Ingeniería de datos	7
4. Análisis exploratorio	12
4.1. Valores ausentes, nulos, variables unarias, imputación, normalización, varianza	12
4.1.1. Categóricas	12
4.1.2. Numéricas	12
4.2. Extremos	13
4.3. Multicolinealidad	17
5. Creación tad	24
6. Link al dashboard	25
7. Conclusión	26

Capítulo 1

Introducción

Dormir no es simplemente una necesidad biológica. Aunque pueda parecer algo básico, casi automático que hacemos, algo en lo que rara vez nos detenemos a pensar, pero la experiencia del sueño varía profundamente de una persona a otra y puede cambiar drásticamente, ya que esta actividad se ve influenciada profundamente por las condiciones sociales, económicas y culturales en las que esta inmerso cada persona, dependiendo de su contexto.

Aunque el sueño suele ser tratado desde un enfoque médico o psicológico, en realidad es una experiencia atravesada por múltiples dimensiones y se puede abordar desde diferentes disciplinas. Dormir o no poder dormir afecta el núcleo del desarrollo cotidiano de una persona. Sin embargo, esto no es solo una cuestión individual, sino estructural, porque desde varios ámbitos como desde los horarios laborales, el tiempo de traslado, la calidad del transporte público, la precariedad habitacional, hasta la imposibilidad de sostener rutinas estables. Por eso se debe de estudiar el sueño, ya que no es solo estudiar el cuerpo, sino también observar cómo la sociedad organiza el tiempo, el espacio y la vida cotidiana. La calidad del sueño, el estrés y los factores de salud, incluidas las enfermedades, no pueden separarse de estas condiciones estructurales y de otras variables inherentes a ella.

El sueño es un proceso biológico fundamental para la salud física y mental, permitiendo la restauración del cuerpo, la consolidación de la memoria y la regulación emocional. Sin embargo, su calidad y duración pueden verse afectadas por diversos factores, tanto negativos como positivos. Es por eso que, para el proyecto final del módulo 1 se eligió el público del sitio web Kaggle. El cual contiene información sobre hábitos de sueño, actividad física y características oculares, con un conjunto de datos compuesto por 20,000 registros, y de variables (26) (numéricos, categóricos, booleanos) lo cual facilitará la aplicación dirigida de técnicas de limpieza y transformación vistas en el curso y dar pie al uso de los conocimientos adquiridos. Así, se busca entender los factores relacionados con la calidad del sueño y su relación con diversos factores, sobre los hábitos de sueño, salud física y mental, actividad física, consumo de sustancias (como café y alcohol) y características de su descanso. Estos datos se encuentran en un archivo de tipo csv, el cual, se puede obtener desde el siguiente enlace: Fuente de datos.

El archivo contiene información relacionada con hábitos de sueño, salud y estilo de vida de los sujetos, como:

- Datos demográficos y físicos
- Sueño y descanso
- Salud física y mental
- Hábitos y consumo
- Salud ocular y uso de pantallas
- Historial médico

Se tomó la decisión de utilizar este conjunto de datos, pues, este ofrece una base sólida para aplicar los conceptos clave del módulo, tales como:

- Análisis exploratorio de datos (EDA)
- Procesamiento de variables numéricas y categóricas
- Técnicas de imputación y limpieza
- Visualizaciones para identificar patrones o outliers

Capítulo 2

Descripción de los datos

2.1. Calidad de los datos

La calidad de los datos es bastante buena incluso antes de que se realice la limpieza, los datos tienen una buena variabilidad, no hay clases desbalanceadas. El dataset no contiene valores nulos en ninguna de sus columnas, lo que garantiza una alta completitud. Esto simplifica el proceso de limpieza, ya que no es necesario aplicar técnicas de imputación ni tampoco comprobar si se alteró o no la distribución de las variables. Los registros no tienen datos extraños, mantienen consistencia con un formato uniforme. Por ejemplo, la columna *edad* solo contiene valores enteros positivos entre 18 y 45. Únicamente se tiene un desbalanceo de clases en la variable *Dry Eye Disease* el cual tiene una distribución de 65,2 % y 34,8 %.

A continuación se observa como es la distribución de datos para las variables categóricas:




Figura 2.1: Gráfica que muestra la distribución de las variables categóricas

Por otro lado, para las variables numéricas se tienen las siguientes distribuciones:




Figura 2.2: Gráfica que muestra la distribución de las variables numéricas

2.2. Pretratamiento

Se ajustaron los tipos de dato de las variables, *string* para las variables categóricas y *float* o *int* para las variables numéricas. Así mismo, se creó una nueva variable llamada *BuenSueno* la cual cataloga en dos la variable de *Sleep quality*, esto con la intención de que se utilice como *target* para el problema 1.

Así, se obtuvo la distribución de variables de la siguiente manera:

- **Categóricas:** Gender, Sleep disorder, Wake up during night, Feel sleepy during day, Caffeine consumption, Alcohol consumption, Smoking, Medical issue, Ongoing medication, Smart device before bed, Blue-light filter, Discomfort Eye-strain, Redness in eye, Itchiness/Irritation in eye, Dry Eye Disease, BuenSueno, Sleep quality
- **Numéricas:** Stress level, Heart rate, Daily steps, Physical activity, Height, Weight, Blood pressure systolic, Blood pressure diastolic, Average screen time, Age, Sleep duration

Sin embargo, dado que se trabajará con dos problemas distintos, se hizo un conjunto de variables para cada problema, dando como resultado:

Problema 1

- **Categóricas:** Gender, Stress level, Sleep disorder, Wake up during night, Feel sleepy during day, Caffeine consumption, Alcohol consumption, Smoking, Medical issue, Ongoing medication, Smart device before bed, Blue-light filter, Discomfort Eye-strain, Redness in eye, Itchiness/Irritation in eye, Dry Eye Disease

- **Numéricas:** Sleep duration, Average screen time, Heart rate, Daily steps, Physical activity, Height, Weight, Blood pressure systolic, Blood pressure diastolic

Además, para la unidad muestral se tiene la columna *id* y para el target la columna *BuenSueno*

Problema 2

- **Catégoricas:** Gender, Stress level, Sleep disorder, Wake up during night, Feel sleepy during day, Caffeine consumption, Alcohol consumption, Smoking, Medical issue, On-going medication, Smart device before bed, Blue-light filter, Discomfort Eye-strain, Redness in eye, Itchiness/Irritation in eye, Dry Eye Disease
- **Numéricas:** Average screen time, Age, Heart rate, Daily steps, Physical activity, Height, Weight, Blood pressure systolic, Blood pressure diastolic

Además, para la unidad muestral se tiene la columna *id* y para el target la columna *BuenSueno*

Capítulo 3

Ingeniería de datos

Se buscó agregar las siguientes variables:

■ Problema 1:

- *Tipo categórica:*
 - Heart rate: [Bradicardia, Normal, Elevada, Taquicardia]
 - Daily steps: [Sedentario, Poco activo, Moderadamente activo, Activo, Muy activo]
 - Physical activity: [Sedentario, Poco activo, Moderadamente activo, Muy activo]
 - Height dependiendo del género.
 - BMI (numérica) y tipo de peso
 - Stress level: [baja, media, alta]
 - **Sleep duration:** [Deficiente, Insuficiente, Adecuado (Mínimo), Óptimo, Excesivo]
 - Average screen time: ['Mínimo', 'Moderado', 'Alto', 'Muy Alto', 'Extremo']
 - Blood pressure: [Hipotensión, Normal, Elevada, Hipertensión Grado 1, Hipertensión Grado 2]
- *Tipo numérica:*
 - Ratio entre cada par de variables
 - Interacción entre cada par de variables

■ Problema 2:

- *Tipo categórica:*
 - **Age:** [joven, adulto, adulto mayor]
 - Average screen time: ['Mínimo', 'Moderado', 'Alto', 'Muy Alto', 'Extremo']

- Stress level: [baja, media, alta]
- Heart rate: [Bradycardia, Normal, Elevada, Taquicardia]
- Daily steps: [Sedentario, Poco activo, Moderadamente activo, Activo, Muy activo]
- Physical activity: [Sedentario, Poco activo, Moderadamente activo, Muy activo]
- Height dependiendo del género.
- BMI (numérica) y tipo de peso
- Blood pressure: [Hipotensión, Normal, Elevada, Hipertensión Grado 1, Hipertensión Grado 2]
- *Tipo numérica:*
 - Ratio entre cada par de variables
 - Interacción entre cada par de variables

De tal modo que, se obtuvieron las siguientes distribuciones para las variables creadas:




Figura 3.1: Gráfica que muestra la distribución de las variables categóricas nuevas para el problema 1




Figura 3.2: Gráfica que muestra la distribución de las variables numéricas nuevas para el problema 1





Figura 3.3: Gráfica que muestra la distribución de las variables categóricas nuevas para el problema 2



Capítulo 4

Análisis exploratorio

4.1. Valores ausentes, nulos, variables unarias, imputación, normalización, varianza

4.1.1. Categóricas

Dado que no se encontraron variables con registros nulos en las variables categóricas del problema 1, se procedió a hacer el análisis de frecuencias y al realizar la normalización se obtuvo que no hubieron categorías pequeñas, teniendo en cuenta que el mínimo fue de 0.03 para la frecuencia relativa.

Se obtuvieron resultados similares para el problema 2 en las variables categóricas.

Tampoco se encontraron variables unarias en ninguno de los dos problemas.

4.1.2. Numéricas

No se cuenta con valores ausentes en los dos conjuntos de datos numéricos, por lo tanto, no se realizó imputación ni tampoco existió el riesgo de que la distribución de alguna variable se haya visto afectada.

Para la varianza, se buscaron las variables donde la varianza era menor o igual a 1 en ambos problemas y se descartaron para su uso. Para el caso del problema 1 se encontraron 65 variables: Average screen time_/_BMI, Average screen time_/_Blood pressure diastolic, Average screen time_/_Blood pressure systolic, Average screen time_/_Daily steps, Average screen time_/_Heart rate, Average screen time_/_Height, Average screen time_/_Physical activity, Average screen time_/_Weight, Blood pressure diastolic_/_BMI, Blood pressure systolic_/_Blood pressure diastolic, BuenSueno, Heart rate_/_Blood pressure diastolic, Heart rate_/_Blood pressure systolic, Heart rate_/_Daily steps, Heart rate_/_Height, Heart rate_/_Weight, Height_/_Blood pressure diastolic, Height_/_Blood pressure systolic, Height_/_Weight, Physical activity_/_Blood pressure diastolic, Physical activity_/_Blood pressure systolic, Physical activity_/_Height, Physical activity_/_Weight, Sleep duration_/_BMI, Sleep duration_/_Blood pressure diastolic, Sleep duration_/_Blood pressure systolic, Sleep duration_/_Daily steps,

Sleep duration__/_Heart rate, Sleep duration__/_Height, Sleep duration__/_Physical activity, Sleep duration__/_Weight, Weight__/_BMI, Weight__/_Blood pressure diastolic, Weight__/_Blood pressure systolic, Daily steps__/_Physical activity, Heart rate__/_Physical activity, Sleep duration__/_Average screen time.

Para el problema 2 se obtuvieron un total de 63 variables: Age__/_BMI, Age__/_Blood pressure diastolic, Age__/_Blood pressure systolic, Age__/_Daily steps, Age__/_Heart rate, Age__/_Height, Age__/_Weight, Average screen time__/_Age, Average screen time__/_BMI, Average screen time__/_Blood pressure diastolic, Average screen time__/_Blood pressure systolic, Average screen time__/_Daily steps, Average screen time__/_Heart rate, Average screen time__/_Height, Average screen time__/_Physical activity, Average screen time__/_Weight, Blood pressure diastolic__/_BMI, Blood pressure systolic__/_Blood pressure diastolic, Heart rate__/_Blood pressure diastolic, Heart rate__/_Blood pressure systolic, Heart rate__/_Daily steps, Heart rate__/_Height, Heart rate__/_Weight, Height__/_Blood pressure diastolic, Height__/_Blood pressure systolic, Height__/_Weight, Physical activity__/_Blood pressure diastolic, Physical activity__/_Blood pressure systolic, Physical activity__/_Height, Physical activity__/_Weight, Weight__/_BMI, Weight__/_Blood pressure diastolic, Weight__/_Blood pressure systolic, Age__/_Physical activity, Average screen time*_Physical activity, Daily steps*_Physical activity, Daily steps__/_Physical activity, Heart rate__/_Physical activity, Heart rate*_Height.

4.2. Extremos


Se obtuvo la siguiente tabla con los porcentajes de registros de valores extremos para ambos problemas:

Cuadro 4.1: Porcentaje de registros extremos vs no extremos

Problema	% registros extremos	% registros no extremos
1	42,74	57,26
2	41,04	58,96

Luego de obtener dichos registros, se decidió eliminar los extremos, con el proposito de que el modelo pudiera aprender mejor de los datos no extremos y así poder obtener un mejor resultado.

Para el problema 1 se obtuvo la siguiente matriz de correlación:






Figura 4.2: Gráfica que muestra la distribución de las correlaciones para el problema 1

Por otro lado, para el problema 2 se generó la siguiente matriz de correlación:




Figura 4.3: Matriz que muestra la distribución de las correlaciones para el problema 2

Y las siguientes gráficas que muestran la correlación lineal entre las variables:




Figura 4.4: Gráfica que muestra la distribución de las correlaciones para el problema 2

4.3. Multicolinealidad

Mediante la técnica de varclushi se logró identificar la multicolinealidad entre las variables, lo cual permitió agrupar las variables predictoras correlacionadas en clusters. Lo cual facilitará la selección de las variables representativas para cada cluster, lo que optimizará el modelo pero sin perder información relevante.

Cluster	Variable	RS_Own	RS_NC	RS_Ratio	ID
Cluster	Variable	RS_Own	RS_NC	RS_Ratio	id
0	Daily steps	1.00	0.01	0.00	1
0	Daily steps_*_Height	0.97	0.01	0.03	2
0	Daily steps_/_Height	0.97	0.02	0.03	3
0	Daily steps_*_Blood pressure diastolic	0.94	0.04	0.07	4
0	Daily steps_/_Blood pressure diastolic	0.94	0.05	0.07	5
0	Daily steps_/_Blood pressure systolic	0.93	0.05	0.08	6
0	Daily steps_*_Blood pressure systolic	0.93	0.05	0.08	7
0	Heart rate_*_Daily steps	0.92	0.06	0.08	8
0	Daily steps_*_Weight	0.86	0.10	0.16	9
0	Daily steps_/_Weight	0.85	0.11	0.17	10
0	Sleep duration_*_Daily steps	0.81	0.17	0.22	11
0	Daily steps_*_BMI	0.79	0.16	0.24	12
0	Daily steps_/_BMI	0.79	0.16	0.25	13
0	Average screen time_*_Daily steps	0.54	0.38	0.75	14
1	BMI	0.98	0.43	0.03	1
1	Height_/_BMI	0.90	0.42	0.18	2
1	Blood pressure diastolic_*_BMI	0.82	0.38	0.29	3
1	Height_*_BMI	0.92	0.73	0.32	4
1	Weight_*_BMI	0.91	0.71	0.33	5
1	Blood pressure systolic_/_BMI	0.75	0.31	0.36	6
1	Blood pressure systolic_*_BMI	0.76	0.38	0.38	7
1	Heart rate_*_BMI	0.70	0.35	0.46	8
1	Heart rate_/_BMI	0.70	0.48	0.57	9
1	Sleep duration_*_BMI	0.53	0.43	0.83	10
2	Average screen time	0.98	0.00	0.02	1
2	Average screen time_*_Height	0.94	0.02	0.06	2
2	Average screen time_*_Blood pressure diastolic	0.92	0.05	0.08	3
2	Average screen time_*_Blood pressure systolic	0.92	0.05	0.09	4

Continúa en la siguiente página

Cuadro 4.2 – Continúa de la página anterior

Cluster	Variable	RS_Own	RS_NC	RS_Ratio	ID
2	Average screen time_*_Heart rate	0.90	0.07	0.11	5
2	Average screen time_*_Weight	0.89	0.12	0.13	6
2	Average screen time_*_BMI	0.82	0.18	0.22	7
2	Sleep duration_*_Average screen time	0.78	0.19	0.26	8
2	Average screen time_*_Physical activity	0.41	0.55	1.31	9
3	Sleep duration_*_Physical activity	0.86	0.82	0.81	1
3	Daily steps_*_Physical activity	0.59	0.50	0.83	2
3	Heart rate_*_Physical activity	0.93	0.92	0.89	3
3	Physical activity_*_Blood pressure systolic	0.95	0.94	0.93	4
3	Physical activity_*_Blood pressure diastolic	0.95	0.95	0.98	5
3	Physical activity_*_Height	0.97	0.97	1.23	6
3	Physical activity	0.98	1.00	5.02	7
4	Sleep duration	0.97	0.01	0.03	1
4	Sleep duration_*_Height	0.90	0.06	0.10	2
4	Sleep duration_*_Blood pressure diastolic	0.84	0.17	0.19	3
4	Sleep duration_*_Blood pressure systolic	0.83	0.17	0.21	4
4	Sleep duration_*_Heart rate	0.78	0.21	0.27	5
5	Blood pressure systolic	0.90	0.04	0.10	1
5	Height_*_Blood pressure systolic	0.82	0.19	0.23	2
5	Blood pressure systolic_*_Blood pressure diastolic	0.72	0.40	0.47	3
6	Weight	0.94	0.58	0.13	1
6	Height_*_Weight	0.85	0.21	0.19	2
6	Weight_*_Blood pressure systolic	0.73	0.40	0.45	3

Continúa en la siguiente página

Cuadro 4.2 – Continúa de la página anterior

Cluster	Variable	RS_Own	RS_NC	RS_Ratio	ID
6	Weight_*_Blood pressure diastolic	0.75	0.45	0.45	4
6	Heart rate_*_Weight	0.67	0.36	0.51	5
6	Sleep duration_*_Weight	0.44	0.58	1.34	6
6	Physical activity_*_Weight	0.13	0.88	7.29	7
7	Heart rate	0.89	0.24	0.14	1
7	Heart rate_*_Blood pressure diastolic	0.76	0.34	0.37	2
7	Heart rate_*_Blood pressure systolic	0.74	0.36	0.41	3
8	Blood pressure diastolic	0.91	0.04	0.09	1
8	Height_*_Blood pressure diastolic	0.91	0.21	0.11	2
9	Physical activity_*_BMI	0.83	0.81	0.88	1
9	Physical activity_/_BMI	0.83	0.82	0.95	2
10	Height	0.73	0.32	0.39	1
10	Heart rate_*_Height	0.73	0.66	0.80	2
11	id	1.00	0.00	0.00	1

Para el problema 2 se obtuvo la siguiente tabla de multicolinealidad:

Cluster	Variable	RS_Own	RS_NC	RS_Ratio	ID
Cluster	Variable	RS_Own	RS_NC	RS_Ratio	id
0	Daily steps	1.00	0.00	0.00	1
0	Daily steps_/_Height	0.97	0.01	0.03	2
0	Daily steps_*_Height	0.97	0.01	0.03	3
0	Daily steps_*_Blood pressure diastolic	0.94	0.04	0.07	4
0	Daily steps_/_Blood pressure diastolic	0.94	0.05	0.07	5
0	Daily steps_*_Blood pressure systolic	0.93	0.05	0.07	6
0	Daily steps_/_Blood pressure systolic	0.93	0.05	0.08	7
0	Heart rate_*_Daily steps	0.92	0.06	0.09	8
0	Daily steps_*_Weight	0.86	0.10	0.16	9
0	Daily steps_/_Weight	0.85	0.11	0.16	10
0	Daily steps_*_BMI	0.80	0.16	0.24	11
0	Age_*_Daily steps	0.80	0.17	0.25	12
0	Daily steps_/_BMI	0.79	0.16	0.25	13

Continúa en la siguiente página

Cuadro 4.3 – Continúa de la página anterior

Cluster	Variable	RS_Own	RS_NC	RS_Ratio	ID
0	Average screen time_*_Daily steps	0.54	0.38	0.75	14
1	BMI	0.99	0.42	0.02	1
1	Height_/_BMI	0.92	0.24	0.10	2
1	Blood pressure diastolic_*_BMI	0.82	0.37	0.28	3
1	Blood pressure systolic_/_BMI	0.75	0.30	0.36	4
1	Blood pressure systolic_*_BMI	0.77	0.37	0.37	5
1	Heart rate_/_BMI	0.70	0.29	0.42	6
1	Weight_*_BMI	0.87	0.71	0.44	7
1	Height_*_BMI	0.88	0.73	0.44	8
1	Heart rate_*_BMI	0.70	0.36	0.47	9
1	Height	0.38	0.04	0.65	10
1	Age_*_BMI	0.50	0.46	0.92	11
2	Physical activity	0.99	0.00	0.01	1
2	Physical activity_*_Height	0.98	0.00	0.02	2
2	Physical activity_*_Blood pressure diastolic	0.95	0.03	0.05	3
2	Physical activity_*_Blood pressure systolic	0.95	0.03	0.05	4
2	Heart rate_*_Physical activity	0.94	0.06	0.07	5
2	Physical activity_*_Weight	0.91	0.08	0.10	6
2	Physical activity_*_BMI	0.84	0.13	0.18	7
2	Age_*_Physical activity	0.84	0.13	0.19	8
2	Physical activity_/_BMI	0.81	0.11	0.21	9
3	Average screen time	0.98	0.00	0.02	1
3	Average screen time_*_Height	0.95	0.01	0.06	2
3	Average screen time_*_Blood pressure diastolic	0.93	0.05	0.08	3
3	Average screen time_*_Blood pressure systolic	0.92	0.05	0.08	4
3	Average screen time_*_Heart rate	0.90	0.08	0.11	5

Continúa en la siguiente página

Cuadro 4.3 – Continúa de la página anterior

Cluster	Variable	RS_Own	RS_NC	RS_Ratio	ID
3	Average screen time_*_Weight	0.90	0.12	0.12	6
3	Average screen time_*_BMI	0.82	0.18	0.22	7
3	Average screen time_*_Age	0.78	0.20	0.28	8
4	Age	0.97	0.01	0.03	1
4	Age_*_Height	0.91	0.02	0.09	2
4	Age_*_Blood pressure diastolic	0.85	0.13	0.17	3
4	Age_*_Blood pressure systolic	0.84	0.16	0.19	4
4	Age_*_Heart rate	0.80	0.23	0.26	5
5	Blood pressure systolic	0.90	0.01	0.10	1
5	Height_*_Blood pressure systolic	0.77	0.11	0.25	2
5	Blood pressure systolic_*_Blood pressure diastolic	0.66	0.38	0.55	3
5	Heart rate_*_Blood pressure systolic	0.57	0.56	0.98	4
6	Weight	0.95	0.51	0.11	1
6	Height_*_Weight	0.86	0.15	0.17	2
6	Weight_*_Blood pressure diastolic	0.75	0.40	0.41	3
6	Weight_*_Blood pressure systolic	0.74	0.36	0.41	4
6	Heart rate_*_Weight	0.68	0.36	0.50	5
6	Age_*_Weight	0.42	0.60	1.47	6
7	Blood pressure diastolic	0.87	0.03	0.13	1
7	Height_*_Blood pressure diastolic	0.80	0.10	0.22	2
7	Heart rate_*_Blood pressure diastolic	0.62	0.60	0.94	3
8	Heart rate	1.00	0.06	0.00	1
9	Sleep quality	1.00	0.00	0.00	1
10	id	1.00	0.00	0.00	1

De este modo, para ambos problemas se realizó una división en 10 clusters, lo que implica que las variables dentro de cada grupo presentan multicolinealidad entre sí.

Para la discretización de las variables se hizo lo siguiente:

Problema Columnas Discretizadas

1	Daily steps
1	BMI
1	Average screen time
1	Sleep duration_*_Physical activity
1	Sleep duration
1	Blood pressure systolic
1	Weight
1	Heart rate
1	Blood pressure diastolic
1	Physical activity_*_BMI
1	Height
2	Daily steps
2	BMI
2	Physical activity
2	Average screen time
2	Age
2	Blood pressure systolic
2	Weight
2	Blood pressure diastolic
2	Heart rate
2	Sleep quality

Capítulo 5

Creación tad

El proceso de selección de variables se realizó mediante técnicas diferenciadas según la naturaleza de cada problema:

Para el problema 1 se aplicó un análisis exhaustivo mediante Weight of Evidence (WoE) para cuantificar la relación predictiva de cada categoría discreta e Information Value (IV) Como métrica global de predictividad ($IV \in [0,03, 0,8]$)

Todas las variables discretizadas mostraron poder predictivo significativo según el siguiente criterio:

$$IV \geq 0,03 \Rightarrow \text{Retención de todas las variables}$$

Las variables seleccionadas fueron:

- d_Average screen time_4
- d_BMI_4
- d_Blood pressure diastolic_4
- d_Blood pressure systolic_4
- d_Daily steps_4
- d_Heart rate_4
- d_Height_4
- d_Physical activity*_BMI_4
- d_Sleep duration_4
- d_Sleep duration*_Physical activity_4
- d_Weight_4

Para el problema 2 se optó por una transformación directa a variables dummy, dado que la naturaleza multiclase dificulta la aplicación directa de WoE/IV.

Capítulo 6

Link al dashboard

En el siguiente enlace: DASHBOARD. Se encuentra el Dashboard construido el cual cuenta con información relevante sobre el conjunto de datos, además de incluir gráficas y filtros para facilitar la visualización de su distribución y cómo diversos factores pueden o no afectar la calidad de sueño de las personas y cómo sus hábitos y costumbres pueden impulsar un sueño de mayor calidad o lo pueden perjudicar.

Capítulo 7

Conclusión

El sueño puede ser estudiado como una forma de desigualdad, ya que no todas las personas tienen las mismas condiciones para dormir, condiciones que no se pueden ver reflejadas en los registros. Sin embargo, lo que sí se logró observar es como de quienes experimentan altos niveles de estrés o padecen alguna enfermedad pueden o no tener un impacto en su ciclo de sueño, se podría concluir que el sueño es un proceso más individual que colectivo. Pero, se piensa que un conjunto de datos más diverso que buscara recolectar todas las condiciones que podrían influir en el sueño de una persona como el tiempo de traslado, calidad de la cama, estado psicológico, etc. Habrían sido de mayor ayuda para poder entender como las diversas condiciones de vida de las personas se ven afectadas y en consecuencia tienen una mejor o peor noche de sueño. En este sentido, las variables del dataset no solo son datos individuales, sino que reflejan una dimensión colectiva del descanso. Por ejemplo, una mala calidad del sueño puede estar correlacionada con ciertas edades, pero también con estilos de vida que responden a exigencias del sistema económico contemporáneo, como la productividad constante, la conectividad permanente y el debilitamiento de los tiempos de descanso real.

Este análisis puede ser enriquecido desde las teorías críticas del espacio y la reproducción social, como las desarrolladas por el geógrafo marxista David Harvey. En su texto *El derecho a la ciudad*, Harvey plantea que la ciudad no es simplemente un escenario físico, sino un producto colectivo configurado por las relaciones de poder. Así como el capital transforma el espacio urbano en mercancía, también coloniza el tiempo de los sujetos, moldeando sus rutinas, su movilidad y su acceso al descanso. En este marco, el “*derecho al sueño*” podría pensarse como una extensión del “*derecho a la ciudad*”, es decir, como la capacidad de disfrutar de condiciones de descanso dignas, estables y reparadoras, dependen de la factores económicos o sociales, ya que va segmentando a cierta parte de la población. Por lo tanto, se piensa que los resultados obtenidos durante el ejercicio de este proyecto refuerzan la hipótesis de que el sueño depende de más factores que no son solo individuales sino colectivos.