



Reggaeton

ÉXITOS DEL FUTURO



Diplomado en Ciencia de Datos

Por Erick Pérez Mendoza



Índice

Introducción

- 05 Contexto
- 07 Objetivo
- 08 Justificación

Datos


- 04 Descripción de los datos
- 05 Calidad de datos
- 06 Análisis exploratorio
- 07 Ingeniería de variables
- 08 Visualización de datos
- 09 Tabla analítica de datos (TAD)

Modelado

- 10 Modelos probados
- 11 Modelo usado
- 12 Interpretación

Conclusiones

- 13 Conclusión
-



INTRODUCCIÓN



CONTEXTO

El reggaetón Mexa ha emergido como una de las expresiones musicales más representativas del entorno juvenil en México. Aunque pueda parecer una simple adaptación local del reggaetón caribeño, este subgénero ha desarrollado una identidad propia, profundamente enraizada en los imaginarios, lenguajes y aspiraciones de los sectores populares. Se trata de una música que no solo se baila, sino que también se vive y representa: en las letras explícitas, en los códigos estéticos, en las formas de hablar, en los espacios donde se escucha.

Sin embargo, reducir el reggaetón Mexa a una mera moda juvenil sería un error. Su crecimiento responde a transformaciones más profundas en la manera en que hoy se produce, se consume y se posiciona la música. Vivimos en una época donde las plataformas digitales como Spotify o Deezer han redefinido las reglas del juego. Ya no es la radio, la televisión o las disqueras quienes deciden qué se escucha y qué no. Son los algoritmos y los datos de consumo quienes tienen ese poder. En ese sentido, el reggaetón Mexa es más que música: es un producto cultural que se encuentra en disputa.

El éxito del reggaetón Mexa surge de una mezcla de autenticidad, elementos culturales locales, estrategias digitales y su impacto en las plataformas. Sin embargo, esta combinación no siempre es fácil de ver a simple vista. Detrás de cada canción viral hay decisiones que no solo tienen que ver con lo artístico, sino también con la duración del track, las palabras que se repiten, la portada que se elige, el momento en que se lanza, el tipo de audio que se usa, entre muchos otros factores que hoy pueden medirse, analizarse y en algunos casos predecirse.

Artistas como Bellakath, Uzielito Mix o El Malilla han logrado consolidarse como referentes del reggaetón Mexa no solo por su propuesta musical, sino por haber sabido leer bien este nuevo contexto. Le hablan a un público específico, su uso de redes sociales, entienden la importancia de las métricas y diseñan su contenido para resonar en un entorno de inmediatez y viralidad. Son artistas que han aprendido a usar a su favor las herramientas del sistema.

Tan solo en 2023, las canciones del reggaetón Mexa se integraron a más de 31 millones de playlists en Spotify. Esa cifra no solo refleja popularidad: revela un fenómeno cultural con una estructura de consumo sólida, una comunidad de oyentes fiel y una lógica de circulación que sigue reglas propias. Es aquí donde entra el papel del análisis de datos. Si las plataformas digitales ya operan como filtros de visibilidad, entonces es fundamental entender qué se mide, cómo se mide, y qué consecuencias tiene eso para los creadores.



Donde se analiza si es posible anticipar su éxito y si podemos encontrar patrones comunes entre las canciones que logran posicionarse bien y aquellas que pasan desapercibida, o qué implicaciones tiene esto para los artistas emergentes que buscan competir en un mercado saturado, sin perder su identidad.

Hoy en día, hablar de música implica también hablar de datos. Cada reproducción, cada clic, cada guardado, cada playlist, cada omisión alimenta sistemas que aprenden a recomendar, a clasificar y a excluir. Pero si esos datos pueden usarse para condicionar la visibilidad de los artistas, también pueden usarse para nivelar el terreno, ofrecer estrategias más inteligentes, y devolver algo de agencia a quienes normalmente están en desventaja frente al sistema.

Este proyecto se propone precisamente eso: construir una lectura crítica y útil del reggaetón Mexa a partir del análisis de datos, con el objetivo de entender cómo operan las lógicas del éxito en la era digital, y cómo esas lógicas pueden ser comprendidas, aprovechadas o incluso desafiadas. Se busca abrir una conversación sobre el papel de los datos en la música contemporánea y ofrecer herramientas concretas a quienes están creando desde abajo, desde la calle, desde los márgenes.

Porque si el reggaetón Mexa ha demostrado algo, es que desde los márgenes también se puede hacer historia. Y si hoy los datos son el nuevo idioma del poder, entonces es momento de aprender a hablarlo, sin perder la esencia, para que la música no solo suene, sino también resista, conecte y transforme.



OBJETIVO

El objetivo de este proyecto es entender qué hace que una canción de reggaetón Mexa tenga éxito en plataformas digitales como Spotify y Deezer. Para lograrlo, se propone crear modelos que puedan predecir el desempeño de una canción antes de que sea lanzada públicamente. Esto no es solo una curiosidad técnica: tener esta información por adelantado puede ayudar a artistas, productores y equipos de trabajo a tomar mejores decisiones. Saber si una canción tiene potencial de ser popular puede servir para mejorar su promoción, reducir riesgos y ajustar detalles creativos antes de invertir tiempo y dinero en su difusión.

El análisis se divide en dos partes:

Regresión

SE BUSCA PREDECIR QUÉ TAN POPULAR SERÁ UNA CANCIÓN EN SPOTIFY, USANDO UNA ESCALA DEL 0 AL 100. PARA ELLO SE CONSIDERAN DATOS COMO CUÁNTAS VECES SE ESCUCHA UNA CANCIÓN, SI LAS PERSONAS LA GUARDAN, LA COMPARTEN O LA REPITEN.

Clasificación

SE INTENTA DETERMINAR SI UNA CANCIÓN SERÁ EXITOSA EN DEEZER, CONSIDERANDO SI LOGRA UNA POSICIÓN POR ENCIMA DEL PROMEDIO EN LOS RANKINGS DE LA PLATAFORMA.

Para construir estos modelos, se usarán datos tanto musicales (como el ritmo, la duración o la energía de la canción) como líricos (es decir, el contenido de la letra), además de otra información básica sobre cada track. Estos datos se obtienen de plataformas como Spotify, Deezer y Genius, y se analizarán con herramientas digitales especializadas.

El resultado final será un sistema que permita anticipar, con base en datos reales, si una canción podría tener buen recibimiento o no. Esto puede ser especialmente útil para quienes están empezando en la industria musical y necesitan una forma más estratégica de planear sus lanzamientos.




JUSTIFICACIÓN

Hoy en día, tener talento y hacer buena música ya no es suficiente para triunfar. Las plataformas de streaming como Spotify y Deezer funcionan con algoritmos que favorecen ciertos tipos de canciones y comportamientos de los usuarios. En este sistema, quienes entienden cómo funcionan los datos tienen una gran ventaja. Por eso, este proyecto busca dar a los artistas herramientas concretas para que puedan tomar decisiones más informadas sobre su música.

Más que describir qué canciones funcionan, este proyecto propone una guía práctica para ayudar a los creadores a mejorar sus resultados. Es una forma de nivelar el terreno en una industria donde muchas veces los recursos y el conocimiento están concentrados en pocas manos.


Algunas de las formas en que este análisis puede ser útil incluyen:




APROVECHAR
MEJOR EL
PRESUPUESTO:
SABER CON
ANTICIPACIÓN
CUÁLES
CANCIONES TIENEN
MÁS POTENCIAL
PERMITE INVERTIR
MEJOR EN SU
PROMOCIÓN.



CREAR MÚSICA
CON MÁS
ESTRATEGIA:
IDENTIFICAR LOS
ELEMENTOS QUE SE
REPITEN EN LAS
CANCIONES
EXITOSAS, PUEDE
AYUDAR A ESCRIBIR
DE MANERA MÁS
EFECTIVA.




REDUCIR LOS
RIESGOS: LANZAR
MÚSICA SIEMPRE
ES UN RIESGO,
PERO SI SE
CUENTA CON
DATOS, SE PUEDEN
TOMAR
DECISIONES MÁS
SEGURAS.



DAR MÁS PODER A
LOS ARTISTAS
INDEPENDIENTES:
AL TENER ACCESO
A ESTE TIPO DE
ANÁLISIS, NO SOLO
LAS GRANDES
DISQUERAS
PODRÁN PLANEAR
CON VENTAJA.

Así que se propone aprovechar las herramientas disponibles en el entorno digital, como los datos, los algoritmos y la posibilidad de hacer predicciones, para que también puedan ser utilizadas por quienes tradicionalmente han tenido menos acceso a ellas. La intención es que el reggaetón Mexa, como manifestación cultural emergente, cuente con recursos que le permitan desarrollarse de manera más sólida, planificada y sostenible.



DATOS



DESCRIPCIÓN DE LOS DATOS

Para la construcción del modelo predictivo se utilizó un conjunto de datos recopilado a partir de tres fuentes principales, cada una con información complementaria sobre las canciones de reggaetón Mexa. La integración de estas fuentes permite un análisis multimodal que combina aspectos técnicos, textuales y comerciales.

SPOTIFY API GENIUS-DEEZER API

- **Spotify API:** Esta fuente proporcionó los metadatos musicales de cada pista, incluyendo identificadores únicos, nombre de la canción, artista principal, nombre del álbum, tipo de álbum (single, compilation o album), fecha de lanzamiento y duración. También se extrajo la variable de popularidad, que es una puntuación dinámica en una escala de 0 a 100, basada en la cantidad de reproducciones recientes y totales en la plataforma.
 - **Genius API:** Se utilizó para obtener las letras limpias de las canciones. El texto fue procesado para eliminar ruido, símbolos, y errores de formato, con el fin de prepararlo para posibles transformaciones de texto en análisis posteriores (por ejemplo, extracción de palabras clave, análisis de sentimiento o embeddings, si se requiere en futuras etapas).
 - **Deezer API:** Aportó variables asociadas a contenido explícito y ranking de popularidad. Las variables incluyen indicadores booleanos sobre si la letra o portada de la canción es explícita, así como un ranking numérico (deezer_rank) que refleja la posición de la canción dentro de la plataforma.
-

Así, de las anteriores fuentes de información mencionadas, se obtuvieron los siguientes datos:

Fuente	Nombre	Descripción
Spotify	spotify_song_id	Identificador único de la pista en Spotify.
Spotify	spotify_song_name	Nombre de la canción.
Spotify	spotify_song_artist	Artista principal de la pista (solo el primer artista si hay múltiples).
Spotify	spotify_song_artists	Lista de todos los artistas que participan en la pista.
Spotify	spotify_album_name	Nombre del álbum al que pertenece la pista.
Spotify	spotify_album_type	Tipo de álbum (album, single o compilation).
Spotify	spotify_album_release_date	Fecha de lanzamiento del álbum (precisión variable: año, mes o día).
Spotify	spotify_song_release_date	Fecha de lanzamiento original de la pista (formato: "YYYYMM" o similar).

Fuente	Nombre	Descripción
Spotify	spotify_song_duration_ms	Duración de la pista en milisegundos.
Spotify	spotify_song_popularity	Popularidad de la pista en una escala de 0 a 100 (100 = más popular).
Genius	genius_lyrics_cleaned	Letra de la canción procesada (sin formato o ruido).
Deezer	deezer_explicit_lyrics	Indica si la pista contiene letras explícitas (booleano: True/False).
Deezer	deezer_explicit_content_lyrics	Nivel de contenido explícito en letras: 0 (No explícito), 1 (Explícito), 2 (Desconocido), 3 (Editado), 6 (Sin información).
Deezer	deezer_explicit_content_cover	Nivel de contenido explícito en la portada (misma codificación que arriba).
Deezer	deezer_rank	Ranking de popularidad de la pista en Deezer (entero).
Librosa	song_info_tempo	Tempo en pulsos por minuto (BPM). Valores altos indican mayor energía o ritmo bailable.

Fuente	Nombre	Descripción
Librosa	song_info_tono	Tonalidad principal de la canción (ej. C, D#), derivada de un análisis espectral.
Librosa	song_info_energia	Intensidad promedio de la pista (Root Mean Square). Valores altos = mayor volumen/dinamismo.
Librosa	song_info_bailabilidad	Índice normalizado (0–1) que combina tempo y fuerza rítmica. 1 = más bailable.
Librosa	song_info_graves	Proporción de energía en frecuencias bajas (≤ 200 Hz). Valores altos sugieren presencia marcada de bajos.



CALIDAD DE DATOS

La base de datos original utilizada en este proyecto contiene un total de 2,109 canciones con 264 variables, muchas de las cuales fueron creadas mediante ingeniería de características a partir de información cruda proveniente de APIs (Spotify, Deezer, Genius) y análisis de audio (Librosa).

El conjunto incluye variables de diversos tipos:



NUME
RICAS



CATEG
ORICAS

- Numéricas continuas y discretas (float64, int64, int32, UInt32) para representar atributos musicales (tempo, duración, energía), métricas textuales (número de sílabas, palabras, rchas, etc.) y rankings.
 - Categóricas y texto libre (object, string) que contienen metadatos de los artistas, nombres de álbumes y canciones, fechas simbólicas y clasificaciones semánticas (estaciones, festividades, emociones).
-



ANÁLISIS EXPLORATORIO

Se confirmaron los siguientes aspectos estructurales:

Duplicados

NO HAY REGISTROS
DUPLICADOS.

Valores ausentes

HAY 119 COLUMNAS CON
VALORES FALTANTES,
AUNQUE LA MAYORÍA
CON UNA PROPORCIÓN
MENOR AL 1%.

Así mismo, las variables `deezer_rank`, `Top1_valor` a `Top9_valor` y `TopX_nombre` presentan nulos en alrededor del 10% de los casos, lo cual es esperable por la naturaleza derivada de estos datos.

INGENIERÍA DE VARIABLES

Durante el preprocesamiento se añadieron múltiples columnas que enriquecen el dataset original. Algunas categorías destacadas incluyen:

- Características fonéticas y poéticas (asonancia y consonancia): Variables como `asonante_mas_frec`, `consonante_max_racha`, `consonante_entropia`, `aliteraciones_totales`, `num_estrofas_lyrics`, entre muchas otras, buscan capturar patrones estilísticos en la letra de la canción.




- Análisis temporal de lanzamiento: Variables como `song_diff_dias_desde_lanzamiento`, `album_estacion`, `song_festivo` y `song_periodo_vacaciones` permiten explorar cómo la temporalidad del lanzamiento puede influir en la popularidad.
- Variables booleanas lógicas (`is_remix`, `is_collab`, `is_song_name_upper`, etc.): Se diseñaron para detectar patrones estructurales o de estilo en los metadatos de las canciones y álbumes.

- Text Mining en metadatos: Columnas como `song_name_emocion`, `artist_name_emocion` y `album_name_emocion` categorizan el sentimiento asociado al nombre de cada entidad.
- Características del contenido lírico: Incluyen métricas como `num_palabras_lyrics`, `prop_adj`, `flesch_szigriszt`, `media_ppv`, `tipo_token_ratio`, entre otras, que cuantifican complejidad, estilo y vocabulario.
- Presencia léxica de palabras clave del reggaetón:
- Variables binarizadas como `baby`, `gata`, `culo`, `perreo`, `dale`, etc., identifican palabras comunes en letras del género urbano.

Este enfoque de ingeniería busca representar explícitamente elementos que, aunque subjetivos (como lo vulgar, bailable o emocional), podrían influir en la viralidad de una canción.

VISUALIZACIÓN DE DATOS

Para las variables numéricas tenemos lo siguiente:



Y para las variables categóricas:

TAD

Aunque el conjunto es robusto, se identificó un porcentaje relevante de variables con valores faltantes:

Variables afectadas	% Nulos aprox.
deezer_rank	102%
Top3_valor, Top4_valor, Top5_valor, etc.	101%
Variables líricas específicas	< 1% – 7%
Variables de análisis fonético	< 1%


Estrategia:

- No se eliminaron registros.
- No se realizó imputación en esta fase, pero se identificaron las variables críticas para cada modelo.
- Se trató la ausencia como información en sí misma en ciertos casos (por ejemplo, si no hay rima frecuente o ranking disponible).

Las variables de fecha fueron derivadas correctamente (como song_dia_semana, album_mes, etc.) y se encuentran distribuidas en indicadores temporales como trimestre, semana del año o vacaciones escolares.

No se detectaron errores de tipado o fechas corruptas, gracias al uso de transformaciones controladas con `pandas.to_datetime()` y al manejo explícito de formatos mixtos (YYYY, YYYY-MM, YYYY-MM-DD).

Por otro lado, las variables textuales (object) como album_name, main_artist, feat_artist_1, etc., presentan alta cardinalidad. No obstante, se agruparon o transformaron en categorías útiles (por ejemplo, tipo de colaboración o artista principal). Algunas variables como TopX_nombre contienen muchos None o tokens comunes (“que”, “la”, “no”), lo cual es esperable al extraer las palabras más frecuentes de las letras. Finalmente, se detectaron outliers extremos en rankings (Top1_valor hasta 10,093), probablemente por tracks muy virales en plataformas internacionales. Se conservaron para no perder capacidad predictiva. Sin embargo, luego de la limpieza posterior al anterior proceso se obtuvieron 61 variables del total.



MODELADO



MODELOS PROBADOS

El objetivo principal de este proyecto fue predecir el nivel de éxito de una canción de reggaetón Mexa utilizando como referencia su popularidad en Spotify. Para ello, se utilizó la variable `song_popularity`, una métrica continua que toma valores de 0 a 100, basada en algoritmos internos de la plataforma que consideran número de reproducciones recientes, interacción de usuarios y otros factores no públicos.

Se trató como un problema de regresión supervisada, donde se busca estimar el valor continuo de popularidad de una canción antes de su lanzamiento o durante su ciclo de vida inicial.

- **Selección de variables:** Se eligieron únicamente variables numéricas para evitar problemas de codificación categórica. El conjunto final incluyó más de 100 variables derivadas de características musicales, estructurales, líricas y temporales.
- **Tratamiento de valores faltantes:** Las columnas con valores nulos fueron excluidas para esta fase del análisis, bajo el principio de no imputar datos que puedan distorsionar patrones musicales reales.
- **Escalamiento de características:** Se aplicó `StandardScaler` para normalizar los datos, dado que muchos modelos de regresión (especialmente regularizados) son sensibles a la escala de las variables.
- **División del conjunto de datos:** Se utilizó un split de entrenamiento/prueba de 80/20 con aleatorización para asegurar una representación equilibrada.

Se probaron cinco modelos clásicos de regresión:

Modelo	R ²	MAE	RMSE
Regresión Lineal	1.535	2.064	2.439
Lasso	1.531	2.070	2.439
Ridge	1.493	2.071	2.445
Elastic Net	1.509	2.074	2.443
Regresión Bayesiana	1.476	2.082	2.447



Las métricas muestran que todos los modelos lineales capturaron solo una fracción limitada de la varianza de los datos ($R^2 \approx 0.15$), lo cual sugiere que la relación entre las variables explicativas y la popularidad no es lineal o está mediada por patrones complejos. El MAE promedio osciló entre 20 y 21 puntos, lo que indica desviaciones importantes frente a los valores reales.

MODELO USADO

A diferencia de los modelos lineales, se implementó una red neuronal multicapa (MLPRegressor) con una arquitectura simple pero efectiva, alcanzando un R^2 de 0.42, más del doble que los modelos clásicos, junto con una reducción significativa en el error absoluto medio. Esta mejora se debe a que la red neuronal puede modelar relaciones no lineales entre las variables musicales y la popularidad, algo que los modelos lineales no logran con variables complejas como la entropía de rimas, los patrones fonéticos, el ritmo o el contenido lírico. Además, las interacciones entre elementos textuales, temporales y fonéticos requieren una mayor capacidad de modelado, que la MLP aprovecha mejor. Si bien este enfoque demanda más tiempo de entrenamiento y es menos interpretable que alternativas como Lasso o Ridge, su claro avance en rendimiento lo hace la opción más adecuada para este caso.

Con el objetivo de optimizar el desempeño del modelo MLPRegressor, se aplicó una búsqueda aleatoria de hiperparámetros (usando RandomizedSearchCV) sobre una grilla de configuraciones definidas para la arquitectura, la función de activación, el optimizador y otros parámetros de regularización y aprendizaje:



```
param_grid = {
    'hidden_layer_sizes': [(50, 50, 50), (50, 100, 50), (100,)],
    'activation': ['tanh', 'relu'],
    'solver': ['sgd', 'adam'],
    'alpha': [0.0001, 0.05],
    'learning_rate': ['constant', 'adaptive'],
}
```



La validación cruzada se realizó con 4 folds ($cv=4$) y 10 combinaciones aleatorias ($n_iter=10$). El criterio de evaluación especificado fue "roc_auc", aunque cabe destacar que esta métrica no es la más adecuada para tareas de regresión. Aun así, se utilizó con fines exploratorios, ya que originalmente el modelo también se concibió para ser probado en un escenario binario (éxito vs no éxito).

A pesar del ajuste automático de hiperparámetros, el modelo no mejoró su rendimiento respecto a la configuración inicial ($R^2 \approx 0.42$), lo que indica que la arquitectura base ya estaba bien adaptada al problema. Las posibles ganancias de optimizar hiperparámetros se vieron contrarrestadas por el riesgo de sobreajuste y la sensibilidad a los datos. Además, el espacio de búsqueda estuvo limitado por restricciones computacionales ($n_iter=10$), impidiendo explorar configuraciones más complejas o profundas que podrían haber generado mejoras marginales.




INTERPRETACIÓN

El modelo final seleccionado, una red neuronal multicapa (MLPRegressor), alcanzó un coeficiente de determinación (R^2) de aproximadamente 0.42. Esto significa que el modelo logra explicar cerca del 42% de la varianza observada en la popularidad de las canciones dentro del conjunto de prueba.

Aunque no representa un desempeño extraordinario, este resultado puede considerarse razonablemente positivo dada la complejidad del fenómeno que se intenta modelar y la calidad del dataset disponible.

Los resultados obtenidos pueden explicarse por varios factores interrelacionados. La calidad de los datos se vio afectada desde su origen, ya que la información recopilada mediante APIs públicas (Spotify, Genius, Deezer) presentaba inconsistencias, registros incompletos y valores faltantes. Además, el proceso de ingeniería de características generó más de 200 variables derivadas de estructuras textuales, temporales y fonéticas, lo que introdujo un margen de error inherente al trabajar a gran escala (2,000+ canciones) sin verificación manual exhaustiva. La naturaleza automatizada del procesamiento también permitió que persistieran casos de ruido, duplicidad conceptual o metadatos erróneos, limitando la capacidad del modelo para identificar patrones consistentes. Sin embargo, el R^2 de 0.42 obtenido sugiere que existe una señal detectable en los datos, aunque con margen para mejoras futuras en la calidad de los datos y métodos de representación.



CONCLUSIONES



CONCLUSIÓN

Este proyecto se propuso desarrollar un modelo predictivo capaz de estimar la popularidad de canciones de reggaetón Mexa en plataformas de streaming, con base en una amplia variedad de características musicales, líricas, temporales y estructurales. A lo largo del proceso, se implementaron múltiples modelos de regresión supervisada, aplicando buenas prácticas de análisis como la selección de variables numéricas, la normalización, la división del conjunto de datos en entrenamiento y prueba, y la evaluación con métricas estándar como R^2 , MAE y RMSE.

Los modelos lineales tradicionales (Regresión Lineal, Lasso, Ridge, etc.) presentaron un rendimiento limitado, explicando aproximadamente un 15% de la varianza en los datos. En cambio, el modelo MLPRegressor logró mejorar considerablemente ese desempeño, alcanzando un R^2 cercano a 0.42, lo cual indica una capacidad moderada para capturar patrones en el conjunto.

Este resultado, si bien no es óptimo, es consistente con las condiciones del proyecto:

El dataset fue generado a partir de múltiples fuentes públicas (Spotify API, Deezer API, Genius API), lo cual implicó desafíos en cuanto a calidad de los datos, presencia de valores nulos y posible información incorrecta o desalineada. Se generaron más de 200 variables mediante ingeniería de características automatizada, muchas de ellas basadas en procesos lingüísticos o musicales complejos, que no pudieron ser validadas manualmente por el volumen del conjunto.

Y a pesar de ello, el proyecto demuestra que es posible construir un sistema de modelado predictivo con resultados funcionales utilizando herramientas vistas en clase. Además, pienso que sentó una base sólida para continuar explorando modelos más robustos en fases futuras del diplomado.
