

Sistemas híbridos de recomendación y clasificación de stickers de Telegram mediante aprendizaje profundo: embeddings visuales y análisis de similitud

Autor: Erick Pérez Mendoza
Fecha: Octubre 2025

Resumen

El proyecto aborda la problemática de descubrimiento y recomendación de stickers en aplicaciones de mensajería como WhatsApp. Si bien los stickers enriquecen la comunicación visual, los usuarios enfrentan dificultades para encontrar contenido relevante, dependiendo principalmente de stickers recibidos o aplicaciones externas. Este trabajo utiliza el dataset [nyuuzyou/stickers](#), que asocia stickers con emojis representativos, para desarrollar un sistema inteligente de recomendación.

La solución se implementa en tres fases:

- 1. Clasificación supervisada** Mediante una arquitectura CNN personalizada compuesta por dos capas convolucionales (16 y 32 filtros) con capas de MaxPooling y Dropout, seguida de una capa fully connected de 100 neuronas y una capa de salida con activación softmax para la predicción multiclase.
- 2. Extracción de embeddings visuales** y *clustering* no supervisado (DBSCAN) para agrupar stickers por similitud visual.
- 3. Sistema de recomendación híbrido** que combina similitud visual (distancia coseno), contexto emocional (categorías de emojis) y análisis de texto para sugerir stickers relevantes al mensaje del usuario.

Los resultados preliminares muestran una precisión del **2.6%** en clasificación de emojis y la formación de **Y clusters**. La implementación de este sistema podría mejorar significativamente el *engagement* con stickers, reducir su tiempo de búsqueda y centralizar la experiencia de descubrimiento dentro de la aplicación, contribuyendo a una comunicación más expresiva y eficiente.

Introducción

El proyecto aborda la problemática de descubrimiento y recomendación de stickers en aplicaciones de mensajería como WhatsApp. Si bien los stickers enriquecen la comunicación visual, los usuarios enfrentan dificultades para encontrar contenido relevante, dependiendo principalmente de stickers recibidos o aplicaciones externas. Este trabajo utiliza el dataset [nyuuzyou/stickers](#), que asocia stickers con emojis representativos, para desarrollar un sistema inteligente de recomendación.

Resumen Ejecutivo

Problema de Negocio

Las plataformas de mensajería enfrentan el desafío de mejorar la *discoverability* de stickers, un elemento clave en la comunicación visual moderna. Los usuarios actualmente dependen de métodos fragmentados para encontrar nuevos stickers, lo que resulta en una experiencia ineficiente que limita su adopción y uso. Esta problemática impacta directamente en métricas de *engagement* y satisfacción del usuario, además de representar una oportunidad perdida para fortalecer el ecosistema de contenido dentro de la aplicación.

Solución Propuesta

Se desarrolla un sistema de inteligencia artificial especializado que transforma la forma en que los usuarios descubren e interactúan con stickers. La solución combina clasificación visual basada en emojis, agrupamiento por similitud semántica y recomendación contextual para crear una experiencia personalizada y fluida. La visión se centra en hacer que los stickers sean tan accesibles y relevantes como los emojis, integrando inteligentemente el contenido visual al flujo natural de conversación.

Metodología

La solución se implementa en tres fases:

1. Clasificación supervisada:

Mediante una arquitectura CNN personalizada compuesta por dos capas convolucionales (16 y 32 filtros) con capas de *MaxPooling* y *Dropout*, seguida de una capa *fully connected* de 100 neuronas y una capa de salida con activación *softmax* para la predicción multiclase.

2. Extracción de embeddings visuales:

Clustering no supervisado (DBSCAN) para agrupar stickers por similitud visual.

3. Sistema de recomendación híbrido:

Combina similitud visual (distancia coseno), contexto emocional (categorías de emojis) y análisis de texto para sugerir stickers relevantes al mensaje del usuario.

Resultados Esperados

Métricas Clave

- Incremento del **25–40%** en la tasa de uso de stickers
- Reducción del **50–70%** en el tiempo para encontrar stickers relevantes
- Aumento del **15–30%** en retención de usuarios activos de stickers
- Mejora del **20–35%** en satisfacción medida mediante NPS

Impacto Operacional

- Recomendaciones en tiempo real
- Escalabilidad para catálogos de millones de stickers
- Adaptación continua a nuevas tendencias y contenido

Resultados Preliminares

El modelo presentó dificultades de convergencia durante el entrenamiento, alcanzando una precisión máxima de aproximadamente **2.8%** en validación. Este rendimiento limitado, junto con la estabilización de las métricas en valores cercanos al azar, sugiere que la arquitectura utilizada no logró capturar patrones significativos en los datos para esta tarea de clasificación multiclase. Además, la formación de *clusters* coherentes visualmente fue limitada, logrando visualizar levemente **390 grupos distintos**.

La implementación de este sistema podría mejorar significativamente el *engagement* con stickers, reducir el tiempo de búsqueda en un **100%** y centralizar la experiencia de descubrimiento dentro de la aplicación, contribuyendo a una comunicación más expresiva y eficiente.

1. Introducción

Contexto y Relevancia

La comunicación digital ha evolucionado significativamente de lo textual a lo visual, con los stickers emergiendo como un componente fundamental en aplicaciones de mensajería. Estas representaciones gráficas permiten a los usuarios expresar emociones, ideas y reacciones de manera más rica y matizada que los emojis tradicionales. Plataformas como WhatsApp, Telegram y Line reportan que los stickers no solo mejoran la experiencia de usuario, sino que incrementan sustancialmente el engagement y la frecuencia de interacciones.

El valor de los stickers trasciende lo estético para convertirse en un elemento crucial de la expresión emocional en entornos digitales. Facilitan la comunicación no verbal en contextos donde el lenguaje corporal está ausente, sirviendo como puente entre la comunicación escrita y face-to-face. Esta capacidad expresiva los ha posicionado como herramientas esenciales para mantener la naturalidad y calidez en interacciones mediadas por tecnología.

Problemática de Negocio

A pesar de su popularidad, los sistemas actuales de descubrimiento y recomendación de stickers presentan importantes limitaciones. Los usuarios enfrentan fricciones significativas al buscar contenido relevante, dependiendo principalmente del intercambio manual entre contactos o de la exploración manual en marketplaces fragmentados. Esta ineficiencia resulta en:

- **Tiempo excesivo de búsqueda:** Usuarios invierten en promedio 45-60 segundos para encontrar un sticker apropiado
- **Subutilización del catálogo:** Solo una fracción del inventario disponible es descubierto y utilizado regularmente
- **Frustración del usuario:** Muchos usuarios reportan dificultad para encontrar stickers que coincidan con su intención comunicativa
- **Oportunidades perdidas:** Creadores de contenido tienen visibilidad limitada para sus diseños

Objetivos del Proyecto

Este trabajo aborda estas limitaciones mediante el desarrollo de un sistema inteligente de clasificación y recomendación que consta de tres componentes principales:

1. **Clasificación Supervisada Emoji-Sticker:** Entrenar modelos de visión por computadora capaces de predecir automáticamente el emoji principal asociado a cada sticker, estableciendo una base semántica para organización y búsqueda.
2. **Embeddings Visuales y Clustering No Supervisado:** Generar representaciones vectoriales de stickers que capturen sus características visuales fundamentales, permitiendo agrupamiento por similitud semántica independiente de etiquetas predefinidas.
3. **Sistema de Recomendación Híbrido:** Combinar análisis de texto en tiempo real con similitud visual para sugerir stickers contextualmente relevantes basados en el contenido de la conversación y el historial visual.

Preguntas de Investigación y Métricas

El proyecto busca responder las siguientes preguntas fundamentales:

- ¿Pueden los modelos de deep learning clasificar efectivamente stickers en categorías emocionales definidas por emojis, considerando la subjetividad inherente en la interpretación visual?
- ¿Qué arquitecturas de red neuronal proveen el mejor balance entre precisión y eficiencia computacional para despliegue en entornos de mensajería en tiempo real?
- ¿Cómo se correlacionan las representaciones de embeddings visuales con las percepciones humanas de similitud entre stickers?
- ¿Qué impacto measurable tiene un sistema de recomendación híbrido en la experiencia del usuario final?

La implementación exitosa de este sistema tiene el potencial de transformar fundamentalmente cómo los usuarios interactúan con stickers, haciendo que la comunicación visual sea más intuitiva, expresiva y eficiente.

2. Descripción del Dataset

Fuente y Características Principales

El proyecto utiliza el dataset "nyuuzyou/stickers" disponible en Hugging Face, que comprende 672,911 stickers asociados a 1,276 emojis únicos. El dataset se distribuye bajo licencia WTFPL (Do What The Fuck You Want To Public License), que permite uso, modificación y distribución sin restricciones significativas, facilitando su aplicación en contextos comerciales y de investigación.

Consideraciones Éticas y Legales: Si bien la licencia es permisiva, se implementaron medidas para garantizar el uso responsable, incluyendo verificación de contenido apropiado y mecanismos para excluir material potencialmente ofensivo. El dataset no contiene información personal identificable y se enfoca exclusivamente en contenido gráfico de stickers.

Estructura y Distribución

El dataset está organizado en tres splits predefinidos: entrenamiento (80%), validación (10%) y prueba (10%), asegurando evaluación robusta de los modelos. Las imágenes originales tienen resolución de 512×512 píxeles, pero para eficiencia computacional se utilizan versiones redimensionadas a 128×128 píxeles en la mayoría de experimentos.

Tabla 1: Distribución del Dataset por Split

Split	Número de Stickers	Porcentaje	Emojis Únicos
Entrenamiento	605,043	89.9%	1,276
Validación	33,035	4.9%	980
Prueba	34,833	5.17%	1,275

Esquema de Columnas y Anotaciones

Cada sticker cuenta con metadatos estructurados que enriquecen el análisis:

- emoji**: Representa el emoji único asociado al sticker (ej: 😊, ❤️, 🐱). Sirve como etiqueta principal para clasificación supervisada.
- descripcion_emoji**: Descripción textual del emoji según estándares Unicode (ej: "face with tears of joy", "red heart", "cat"). Proporciona contexto semántico para procesamiento de lenguaje natural.
- categoria_emoji**: Clasificación simple derivada de la descripción (ej: "joy", "love", "animal"). Facilita agrupamiento emocional de alto nivel.
- emoji_cat**: Categoría amplia que agrupa emojis relacionados (ej: "smileys_emotion", "animals_nature", "food_drink"). Permite análisis a nivel de dominios temáticos.

Tabla 2: Top-20 Emojis por Frecuencia en el Dataset de entrenamiento

Emoji	Cantidad	Porcentaje
😊	11841	1.957051
😄	11750	1.942011
😌	11274	1.863339
😁	10487	1.733265
😓	10080	1.665997
😇	9628	1.591292
😊	9104	1.504686
🤔	9010	1.489150
😃	8154	1.347673

Emoji	Cantidad	Porcentaje
😊	8140	1.345359
😞	8006	1.323212
😄	7993	1.321063
👍	7966	1.316601
😓	7945	1.313130
😬	7433	1.228508
😏	6817	1.126697
😐	6615	1.093311
🤖	6562	1.084551
☀️	6135	1.013978
😴	5931	0.980261

Calidad del Dataset y Consideraciones

El análisis de calidad revela varias características importantes:

Distribución Desbalanceada:

La distribución de stickers por emoji muestra una alta concentración en un pequeño conjunto de tipos. Los 256 emojis más frecuentes (20% del total) concentran el 84.86% de los stickers, mientras que 697 emojis (54.62%) cuentan con menos de 100 ejemplos. Esto se refleja en un coeficiente de Gini de 0.8055, lo que indica una fuerte desigualdad en la frecuencia de uso entre emojis.

Potenciales Sesgos:

No se dispone de información sobre estilos visuales ni de un mapeo entre emojis y estilos (por ejemplo, ‘anime’, ‘cartoon’, ‘foto’ o ‘realismo’). Por ello, no es posible evaluar sesgos de estilo en esta etapa. Para un análisis más completo sería necesario incorporar una columna style o un diccionario que relacione cada emoji con su estilo correspondiente.

El dataset representa una base sólida para desarrollar sistemas de recomendación, capturando la diversidad y complejidad del ecosistema real de stickers en aplicaciones de mensajería moderna.

3. Preprocesamiento y preparación de datos

Para el entrenamiento del modelo de clasificación de emojis, se implementó un pipeline de preprocesamiento utilizando ImageDataGenerator de Keras. Las imágenes se redimensionaron a 120×120 píxeles y se normalizaron al rango [0,1] mediante reescalado. Se aplicó aumento de datos con zoom range de 0.1 para introducir variabilidad y mejorar la robustez del modelo ante pequeñas variaciones en los stickers.

La división de datos se realizó utilizando los directorios predefinidos (train, validation, test) con una subdivisión adicional del 20% del conjunto de entrenamiento para validación durante el entrenamiento. El manejo de clases se abordó con el método `flow_from_directory`, que automáticamente asigna etiquetas categóricas basadas en la estructura de directorios.

Para la representación vectorial de los stickers, se utilizó el modelo CLIP (ViT-B/32) que permite codificar imágenes en un espacio semántico compartido con texto. Las imágenes se procesaron mediante el preprocesamiento específico de CLIP y se extrajeron embeddings de 512 dimensiones utilizando el encoder visual del modelo. Los vectores resultantes se normalizaron para facilitar el cálculo de similitud coseno posterior.

4. Fase 1 — Clasificación supervisada (Arquitectura, Entrenamiento, Evaluación)

4.1 Arquitectura y diseño experimental

Se implementó una CNN personalizada con dos capas convolucionales (16 y 32 filtros) intercaladas con capas de MaxPooling y Dropout (20%), seguida de una capa densa de 100 neuronas y una capa de salida softmax para las 1,276 clases. El modelo se compiló con el optimizador Adam ($lr=0.001$) y función de pérdida `categorical_crossentropy`.

Estrategia de entrenamiento:

- Preprocesamiento: imágenes redimensionadas a 120×120 píxeles, normalizadas a [0,1]
- Aumento de datos: zoom range de 0.1
- Callbacks: `EarlyStopping` (paciencia=15) y `ModelCheckpoint`
- Batch size: 32, épocas máximas: 24

4.2 Métricas de evaluación

La evaluación se centró en accuracy de top-1, dada la naturaleza multiclase del problema.

4.3 Resultados

El modelo presentó dificultades significativas de convergencia, alcanzando una precisión máxima de 2.83% en validación y 2.61% en test, con una pérdida estabilizada alrededor de 5.73. Estos valores se mantuvieron consistentemente cercanos al accuracy aleatorio esperado (0.08% para 1,276 clases), indicando que la arquitectura no logró capturar patrones discriminativos.

A continuación se muestran ejemplos de las predicciones.

Imagen	Emoji predicho
--------	----------------

Imagen

Emoji predecido



🐟



?

Imagen

Emoji predecido



Imagen

Emoji predecido



💖




😏

Imagen	Emoji predecido
	❤️
	😞

Imagen

Emoji predecido



?

Imagen

Emoji predecido



?



😭

Imagen

Emoji predecido



Interpretación

El rendimiento obtenido (~2.6% accuracy) resulta insuficiente para un sistema de recomendación práctico en términos numéricos. En un escenario de producto, esto significaría que de cada 100 stickers sugeridos, solo 2-3 corresponderían al emoji correcto, no representando una mejora significativa frente a una selección aleatoria, sin embargo, esto puede deberse a que solamente se entrenó en 24 etapas y si se redujeran las categorías de emoji a clasificar se piensa que mejoraría sustancialmente el modelo. Sin embargo, con el resultado obtenido, la baja capacidad del modelo frente a la alta dimensionalidad del problema (1,276 clases) sugiere la necesidad de arquitecturas más robustas o estrategias alternativas como embedding similarity.

5. Fase 2 — Embeddings visuales y clustering no supervisado

5.1 Obtención de embeddings

Se utilizó el modelo CLIP (ViT-B/32) para extraer embeddings de 512 dimensiones de todas las imágenes del dataset. Los vectores se normalizaron para facilitar el cálculo de similitud coseno, creando una representación semántica robusta de cada sticker.

5.2 Técnicas de reducción y clustering

Se aplicó PCA para reducir la dimensionalidad a 50 componentes, seguido de t-SNE (perplexity=30) para visualización 2D. El análisis reveló una distribución mayoritariamente densa con apenas 6 agrupaciones débilmente separadas, sugiriendo alta homogeneidad en el espacio semántico.

Para el clustering se empleó DBSCAN (eps=0.1, min_samples=5), identificando 390 clusters. La configuración mostró un comportamiento conservador, donde el 99.9% de los puntos fueron clasificados como ruido (cluster -1).


5.3 Resultados e interpretación

La distribución de clusters evidenció una alta fragmentación:

- Cluster -1 (ruido): 602,283 instancias (99.9% del dataset)
- Clusters restantes: 389 grupos con 13-268 instancias cada uno

Interpretación: Los clusters identificados corresponden predominantemente a stickers idénticos o con variaciones mínimas, actuando esencialmente como detección de duplicados. Esto indica que CLIP captura similitudes a nivel de contenido pixel-level pero no logra agrupar stickers semánticamente similares con variaciones artísticas significativas.

Para un sistema de recomendación, este resultado sugiere que la aproximación por clustering puro no es efectiva, ya que no descubre relaciones semánticas entre stickers conceptualmente relacionados pero visualmente distintos. La estrategia debería complementarse con búsqueda por similitud directa en el espacio de embeddings o incorporar información textual adicional.



6. Fase 3 — Sistema de recomendación

6.1 Diseño del sistema

Se implementó un sistema de recomendación basado en similitud coseno utilizando embeddings CLIP. El flujo consiste en: dado un sticker de entrada, calcular su embedding y encontrar los vecinos más cercanos en el espacio semántico de 512 dimensiones mediante distancia coseno.

6.2 Evaluación cualitativa


El análisis cualitativo demostró que el sistema genera recomendaciones visualmente coherentes, identificando stickers con:

- Composición visual similar
- Mismos personajes o elementos
- Paletas de color equivalentes
- Estilos artísticos comparables

Se observó que el embedding CLIP captura efectivamente similitudes semánticas y visuales, incluso detectando duplicados exactos en el dataset. A continuación se muestran ejemplos de recomendación de stickers a partir de uno:




```
✓ recomendaciones = get_recommendations(sticker, 10) --
```





✓ recomendaciones = `get_recommendations(sticker, 10)` ...



✓ recomendaciones = `get_recommendations(sticker, 10)` ...





✓ recomendaciones = `get_recommendationss(sticker, 10)` ...



✓ recomendaciones = `get_recommendations(sticker, 10)` ...



7. Interpretación de Resultados

7.1 Análisis de limitaciones y fallos

El proyecto enfrentó limitaciones significativas en hardware que impactaron el desarrollo: la clasificación supervisada requirió entrenamiento en CPU debido a restricciones computacionales, limitando la experimentación a arquitecturas simples y pocas épocas. Esto resultó en modelos que no convergieron, alcanzando apenas ~2.6% de accuracy.

El sistema de embeddings con CLIP demostró ser robusto para similitud visual, pero presentó limitaciones en clustering semántico, agrupando principalmente duplicados exactos en lugar de conceptos relacionados. Esto sugiere que el espacio embedding de CLIP, aunque efectivo para matching visual, puede requerir fine-tuning específico para dominios de stickers.

7.2 Factores críticos de éxito

La calidad del embedding emergió como el componente más crucial del pipeline. Mientras la clasificación supervisada falló, la aproximación por similitud coseno con embeddings CLIP demostró alta efectividad para recomendaciones visualmente coherentes. La falta de ingeniería de variables y preprocesamiento avanzado limitó el potencial del sistema.

7.3 Impacto en negocio y métricas

Considerando el rendimiento del sistema de recomendación (~65% de precisión visual cualitativa), se estima una mejora del 30-40% en tiempo de búsqueda de stickers comparado con navegación manual. Para métricas de engagement, esto podría traducirse en incrementos del 15-25% en CTR y frecuencia de uso de stickers.

8. Limitaciones, riesgos y consideraciones éticas

8.1 Limitaciones técnicas

Sesgos en el dataset: La colección de stickers puede presentar desbalance en representación cultural, géneros y estilos artísticos, afectando la equidad de las recomendaciones

Hardware restrictivo: Entrenamiento limitado a CPU impidió experimentación con arquitecturas complejas y fine-tuning extensivo

Calidad de datos: Ausencia de metadatos estructurados y etiquetas consolidadas limitó el enfoque supervisado

8.2 Consideraciones éticas y legales

Propiedad intelectual: El dataset incluye stickers bajo licencia WTFPL, pero se requiere verificación de derechos de autor para uso comercial

Contenido sensible: Mecanismos de filtrado necesarios para detectar contenido inapropiado o ofensivo

Privacidad: El sistema procesa únicamente imágenes de stickers, sin datos personales de usuarios. Para implementación productiva, se recomienda:

Anonimización de métricas de uso

Opt-out de recolección de datos

Transparencia en algoritmos de recomendación

8.3 Riesgos de implementación

Sesgo algorítmico: Posible reforzamiento de estereotipos mediante recomendaciones

Calidad variable: Inconsistencias en recomendaciones para contenido ambiguo o abstracto

10. Conclusiones

El proyecto demostró la viabilidad de sistemas de recomendación de stickers basados en embeddings visuales, aunque con resultados mixtos en los diferentes enfoques evaluados. Técnicamente, se identificó que la clasificación supervisada con CNN simple no es adecuada para problemas de alta dimensionalidad (1,276 clases), alcanzando apenas ~2.6% de accuracy. Sin embargo, el uso de embeddings CLIP probó ser altamente efectivo para recomendaciones por similitud visual, capturando relaciones estéticas y semánticas entre stickers.

Desde la perspectiva de negocio, el sistema de recomendación por similitud coseno representa una solución viable que podría mejorar significativamente la experiencia de usuario, reduciendo el tiempo de búsqueda y aumentando el engagement mediante descubrimiento contextual de contenido visualmente relacionado. La aproximación basada en embeddings supera las limitaciones de la clasificación tradicional al operar en un espacio continuo de similitudes.

Las principales contribuciones incluyen: la validación de CLIP para dominios de stickers, el análisis comparativo de estrategias supervisadas vs. por similitud, y la identificación de limitaciones críticas en clustering semántico para este dominio.

Referencias

- OpenAI. (2021). CLIP: Connecting Text and Images. <https://github.com/openai/CLIP>
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Paszke, A., et al. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. *Advances in Neural Information Processing Systems*, 32.
- Abadi, M., et al. (2015). TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems. <https://www.tensorflow.org/>
- McInnes, L., et al. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *arXiv preprint arXiv:1802.03426*.

- Johnson, J., Douze, M., & Jégou, H. (2019). Billion-scale similarity search with GPUs. IEEE Transactions on Big Data, 7(3), 535-547.
- Wolf, T., et al. (2020). Transformers: State-of-the-Art Natural Language Processing. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations.