

Ayuda en redacción de guiones para creadores de contenido enfocados en el story telling usando herramientas de modelación e IA

Erick Pérez Mendoza

Noviembre 2025

Resumen

Este proyecto aborda el desafío que enfrentan muchos creadores de contenido en plataformas como TikTok: comprender qué elementos narrativos, visuales y estructurales influyen en el rendimiento de un video. Aunque factores como el guion, la miniatura, los hashtags y el tono emocional tienen un impacto comprobado en la retención y el engagement, los usuarios carecen de herramientas accesibles que analicen estos componentes de forma integrada y ofrezcan retroalimentación accionable.

Para resolver esta problemática, se desarrolló un sistema multimodal que combina técnicas de procesamiento de lenguaje natural, visión por computadora, embeddings semánticos y modelos supervisados de predicción. El proceso incluye un análisis lingüístico del guion mediante métricas narrativas, embeddings textuales y modelos especializados para identificar estilo, densidad y elementos de retención; extracción de características visuales de la miniatura mediante modelos CLIP y clustering no supervisado para detectar patrones estilísticos; y modelación supervisada para clasificar el nivel de viralidad del video y estimar un *score de éxito*.

El sistema se integra en una plataforma interactiva construida en Streamlit que permite al usuario cargar un guion y miniatura, obtener un análisis completo, recibir recomendaciones narrativas mediante un chatbot y generar audio con voz artificial. Los resultados demuestran que la combinación de técnicas multimodales permite capturar patrones significativos relacionados con el desempeño de un video y proveer sugerencias útiles para mejorar su calidad narrativa y visual. El proyecto constituye un asistente práctico para creadores enfocados en storytelling que desean optimizar sus contenidos de manera informada y efectiva.

1. Introducción

En los últimos años, plataformas de video de formato corto como TikTok han transformado de manera radical la forma en que los usuarios consumen y producen contenido digital. Este entorno se caracteriza por una competencia extremadamente alta por la atención, ciclos de consumo acelerados y una oferta casi infinita de videos que compiten entre sí por captar al usuario en los primeros segundos. Como resultado, elementos como el guion, la miniatura, la descripción, los hashtags, el estilo narrativo y la composición visual se han vuelto determinantes para influir en el rendimiento de un video y aumentar su probabilidad de éxito.

A pesar de esta creciente complejidad, la mayoría de los creadores de contenido —especialmente los principiantes— no cuentan con herramientas accesibles, sistemáticas y basadas en evidencia que les permitan comprender qué factores impulsan realmente el éxito de un video. Actualmente, los creadores dependen en gran medida de la intuición, la observación informal de tendencias o la prueba y error, lo cual resulta insuficiente frente al volumen masivo de datos, la velocidad de los cambios y la sofisticación de los algoritmos de recomendación de plataformas como TikTok.

En este contexto surge la necesidad de desarrollar soluciones inteligentes que permitan analizar de manera multimodal (texto + imagen + metadatos) los elementos que conforman un video, identificar patrones de alto rendimiento y ofrecer retroalimentación accionable a los creadores. La combinación de técnicas de aprendizaje automático, modelos de lenguaje avanzados, análisis narrativo y procesamiento de imágenes abre la posibilidad de entender qué funciona.

El presente proyecto tiene como objetivo desarrollar una plataforma integral e inteligente que evalúe de forma automática y explicativa los componentes clave del contenido narrativo en TikTok. La solución incorpora modelos supervisados y no supervisados, modelos multimodales como CLIP y embeddings generados mediante APIs modernas, además de herramientas de IA generativa que permiten ofrecer recomendaciones personalizadas. Esta plataforma analiza guiones a nivel sintáctico, semántico y estructural; identifica patrones visuales relevantes en miniaturas; y finalmente integra todos estos elementos para estimar un score narrativo basado en métricas reales de rendimiento.

El sistema no solo busca describir los factores que contribuyen al éxito de un video, sino también proveer a los creadores de contenido una guía práctica, comprensible y accionable. A través de un chatbot explicativo, dashboards comparativos, análisis de similitud y una interfaz interactiva, la plataforma servirá como un espacio de aprendizaje y optimización continua, ayudando a creadores novatos y experimentados a mejorar sustancialmente la calidad y el impacto de sus videos.

Con ello, este proyecto contribuye tanto al ámbito tecnológico —al construir un sistema multimodal de evaluación de contenido— como al ámbito creativo, al ofrecer herramientas que democratizan el acceso al análisis narrativo y visual basado en datos. En última instancia, la plataforma busca cerrar la brecha entre la producción intuitiva y la producción informada, facilitando que más creadores logren destacar en un ecosistema altamente

competitivo como TikTok.

2. Planteamiento del Problema

En las plataformas de videos cortos como TikTok, comprender cuáles son los factores que determinan el éxito o el bajo rendimiento de un contenido se ha convertido en un desafío creciente. Aunque muchos creadores generan videos con ideas valiosas o con una calidad narrativa aceptable, carecen de mecanismos objetivos que les permitan identificar qué elementos de su contenido influyen positiva o negativamente en el desempeño del video. La intuición, la observación superficial de tendencias o la imitación de otros creadores suelen ser las únicas herramientas disponibles, lo que limita su capacidad para mejorar de manera sistemática.

El rendimiento de un video depende de múltiples factores que interactúan entre sí:

- Estructura del guion y su claridad narrativa,
- Densidad informativa,
- Estilo y tono emocional,
- Efectividad de la miniatura y sus elementos visuales,
- Pertinencia de los hashtags y la descripción,
- Además de factores externos como la competencia o las dinámicas del algoritmo de recomendación.

A pesar de esta multiplicidad de variables, los creadores no cuentan con una herramienta unificada que analice simultáneamente el contenido textual, visual y semántico de sus videos. Existen soluciones aisladas —por ejemplo, recomendadores de hashtags, detectores de rostros o análisis básicos de texto—, pero ninguna integra todos estos componentes ni ofrece un diagnóstico narrativo completo. Esta ausencia dificulta comprender qué hace que un video sea atractivo desde una perspectiva multimodal y basada en datos.

Como consecuencia, los creadores enfrentan incertidumbre en la toma de decisiones y se ven limitados en la posibilidad de desarrollar estrategias narrativas coherentes y efectivas. Sin una retroalimentación clara, sistemática y automatizada, resulta complicado identificar oportunidades de mejora, replicar patrones exitosos o corregir debilidades en sus contenidos.

Por lo tanto, el problema central que motiva este proyecto puede formularse de la siguiente manera:

¿Cómo diseñar un sistema capaz de analizar de forma automática y multimodal los elementos narrativos, visuales y semánticos de videos exitosos en TikTok, para generar recomendaciones precisas, personalizadas y accionables que ayuden a los creadores a optimizar su contenido?

3. Descripción de los Datos

La base de datos utilizada en este proyecto fue construida mediante técnicas de *web scraping* aplicadas a TikTok. Los datos recopilados abarcan ele-

mentos multimodales que permiten realizar un análisis integral del contenido, combinando información auditiva, visual y cuantitativa asociada a cada video. En particular, se recolectaron las siguientes variables:

- **Audio:** Audio completo narrado en el video, utilizado para el análisis lingüístico, semántico y estructural.
- **Miniatura:** Imagen principal que se muestra al usuario al visualizar el perfil del creador, relevante para el estudio de patrones visuales y elementos de atención.
- **Descripción:** Texto asociado al video, incluyendo hashtags y emojis, fundamental para evaluar estrategias de posicionamiento, etiquetado y tono comunicativo.
- **Métricas cuantitativas:** Número de *likes*, comentarios, compartidos y duración del video, las cuales funcionan como indicadores objetivos del rendimiento.
- **Canal:** Identificación del creador y su tipo de contenido, útil para caracterizar estilos narrativos y diferencias entre audiencias.

La recolección de datos se realizó específicamente a partir de videos publicados por tres creadores: *faridieck*, *hernanmartinezl* y *kurz_gesagt*. La elección de estos canales obedece a criterios estratégicos relacionados con diversidad narrativa, calidad del contenido y relevancia dentro del ámbito de divulgación:

- **faridieck:** Seleccionado por ser uno de los referentes más influyentes en videos de análisis, reflexión y narrativa en TikTok. Su estilo destaca por la claridad explicativa, el uso eficiente de guiones estructurados y una alta capacidad de retención, convirtiéndolo en un caso ejemplar para estudiar patrones de éxito en narrativas de corte analítico.
- **hernanmartinezl:** Elegido debido a su estrecha relación creativa con Farid, con quien ha colaborado en varias ocasiones. Aunque comparte una línea narrativa reflexiva, su estilo presenta diferencias notables en tono, ritmo y enfoque, lo que permite comparar variaciones dentro de un mismo género narrativo. Esto enriquece el análisis y facilita la identificación de matices en estrategias de storytelling.
- **kurz_gesagt:** Incorporado como un punto de contraste, ya que su contenido se centra en divulgación científica, investigación y explicaciones visualmente elaboradas. Su estructura narrativa está basada en guiones altamente informativos, lo que introduce una dimensión adicional para el análisis semántico.

La combinación de estos tres canales proporciona un conjunto de datos narrativamente diverso, con variabilidad en estilos, enfoques temáticos, estrategias visuales y niveles de popularidad. Esta heterogeneidad resulta especialmente valiosa para modelar fenómenos relacionados con la viralidad, el rendimiento del contenido y la identificación de patrones narrativos en videos de formato corto.

4. Análisis Exploratorio de Datos

El análisis exploratorio de datos (EDA) se realizó una vez completado el proceso de scraping sobre TikTok. El conjunto original contenía información textual, visual y numérica de cada video, incluyendo métricas de interacción, transcripciones del audio, descripciones y miniaturas. Antes del análisis, se aplicaron procedimientos básicos de limpieza orientados únicamente a garantizar la validez estructural del conjunto, evitando cualquier transformación que pudiera sesgar la distribución real del rendimiento de los videos.

4.1. Limpieza y preparación inicial

Se eliminaron columnas irrelevantes (`index`), registros duplicados basados en la transcripción del video, y entradas que contenían transcripciones no informativas tales como *"music"*, *"zou"* o *choose your character!*". Posteriormente, se seleccionaron únicamente las columnas pertinentes al análisis:

```
['id', 'canal', 'ruta', 'url', 'likes', 'comments', 'shares',  
 'duracion_seg', 'descripcion_archivo', 'transcripcion']
```

Es importante señalar que no se eliminaron valores extremos (*outliers*) en las variables numéricas, ya que estos representan videos de muy alto o muy bajo rendimiento. Filtrarlos implicaría asumir que el comportamiento de la plataforma es homogéneo o que todos los videos tienden al promedio, lo cual contradice la naturaleza real de TikTok, donde la distribución de popularidad es altamente sesgada y con colas largas.

4.2. Análisis descriptivo

Se calcularon estadísticas descriptivas para las principales métricas de interacción. Los resultados evidencian distribuciones con alta asimetría positiva, características de fenómenos virales.

Likes

- Media: 361,356
- Desviación estándar: 647,369
- Rango intercuartílico: 22,475 - 394,075
- Máximo: 7,500,000

Los percentiles altos muestran una cola larga pronunciada, indicando que una pequeña fracción de videos concentra la mayoría del impacto. Este comportamiento se puede visualizar mediante la *Figura 1*.

Comentarios

- Media: 1,392
- Desviación estándar: 2,735




Figura 1: Distribución de likes




Figura 2: Distribución de comentarios

- Percentil 90: 3,426
- Máximo: 40,300

Nuevamente se observa una distribución sesgada, con valores mínimos muy bajos pero un número reducido de videos que genera una cantidad excepcionalmente alta de comentarios.

Shares

- Media: 12,761
- Desviación estándar: 32,248
- Mediana: 2,095
- Máximo: 462,000

Los valores de compartidos muestran una dispersión aún mayor que los comentarios, lo que es coherente con el papel que tienen los *shares* en la viralización de contenido.




Figura 3: Distribución de compartidos




Figura 4: Distribución de duración

Duración del video

- Media: 316 segundos
- Desviación estándar: 484
- Percentil 50: 82 segundos
- Máximo: 3,573 segundos

Existe una gran variabilidad en la duración, desde videos muy breves hasta otros mucho más extensos.

4.3. Procesamiento y generación de variables descriptivas

Después del análisis exploratorio inicial, se aplicó un proceso de limpieza y construcción de variables orientado a enriquecer la representación textual de cada video. Estas transformaciones permiten capturar información semántica, estructural y estilística que es relevante para la modelación posterior.

Unificación del lenguaje mediante traducción

Los videos cuya transcripción o descripción se encontraba originalmente en inglés fueron traducidos al español utilizando el modelo `gpt-5-mini`. La decisión de unificar el idioma responde a dos motivos principales:

- Evitar la dispersión semántica: un dataset multilingüe incrementa la variabilidad lingüística y complica tareas como embeddings, análisis sintáctico y detección de estructuras narrativas.
- Mejorar la cohesión del modelo: un único idioma permite entrenar modelos más consistentes y precisos en tareas de clasificación, clustering y análisis narrativo.

El proceso de traducción se mantuvo fiel al significado original, priorizando la claridad narrativa sobre la literalidad.

Limpieza de texto y extracción de características

Posteriormente, se diseñó una función especializada para limpiar las descripciones y generar variables lingüísticas relevantes. Estas variables permiten capturar elementos estilísticos frecuentes en contenido exitoso, como uso de hashtags, presencia de llamadas a la acción o intensidad emocional.

Las características generadas pueden agruparse en las siguientes categorías:

1) Medición de estructura y extensión del texto Variables como número de caracteres, número de palabras y versiones limpias del texto permiten analizar la complejidad y densidad del contenido escrito. Estas medidas son fundamentales para evaluar si las descripciones extensas o concisas se correlacionan con un mejor rendimiento.

2) Componentes de interacción social Se extrajeron elementos que influyen directamente en la interacción del usuario:

- Número de hashtags.
- Número de emojis.
- Número de URLs externas.

Los hashtags son indicadores clave del alcance potencial de un video, mientras que los emojis aportan tono emocional y estilo comunicativo. Las URLs, por su parte, suelen estar presentes en contenido promocional o de campañas externas.

3) Señales narrativas y persuasivas Se identificaron patrones usados comúnmente para incrementar la interacción:

- Presencia de llamadas a la acción (CTA), tales como “sígueme”, “dale like” o “comparte”.
- Detección de preguntas, que suelen funcionar como ganchos conversacionales.

Ambos elementos son relevantes para medir estrategias activas de engagement dentro de las descripciones.

4) Indicadores emocionales y de énfasis Se calculó la proporción de caracteres en mayúsculas, que puede reflejar intensidad emocional, énfasis o dramatización del mensaje. Este tipo de rasgos estilísticos se ha documentado como relevante en contenido viral.

5) Densidades normalizadas Para obtener métricas comparables entre textos:

- Densidad de hashtags: relación entre hashtags y número de palabras.
- Densidad de emojis: relación entre emojis y número de caracteres.

Estas medidas permiten capturar la frecuencia relativa de elementos que influyen en la expresividad o la capacidad de descubrimiento del contenido.

Integración al dataset

Las variables generadas fueron integradas al *dataframe* original mediante un proceso de transformación estructurado, preservando la columna *id* como clave primaria para asegurar consistencia. De esta manera, cada video cuenta ahora con un conjunto enriquecido de atributos textuales que serán utilizados en etapas de modelación supervisada y no supervisada.

En conjunto, estas transformaciones permiten caracterizar con mayor precisión aspectos semánticos, estilísticos y funcionales del contenido textual, lo cual es fundamental para comprender y predecir el rendimiento de los videos en plataformas como TikTok.

4.4. Extracción de miniaturas y características textuales avanzadas

Luego del EDA inicial y de la limpieza básica, se realizaron dos pasos clave para enriquecer la representación de cada video: (1) la extracción de miniaturas y (2) la generación de *features* textuales avanzadas a partir de las transcripciones.

Extracción de miniaturas

A partir de las URLs y rutas de los videos, se extrajeron las miniaturas asociadas a cada registro. Estas imágenes constituyen la base para el análisis visual posterior (embeddings, clustering y detección de patrones de composición). La justificación de esta etapa radica en que, en plataformas como TikTok, la miniatura actúa como un *gancho visual* que influye de manera directa en la tasa de clics y en la decisión del usuario de consumir o no el contenido. Por ello, disponer de las miniaturas como objetos explícitos en el dataset es un requisito para cualquier modelado multimodal.

Generación de características textuales sobre las transcripciones

Con el objetivo de capturar la riqueza estructural y narrativa de los guiones, se desarrolló una función que extrae un conjunto amplio de variables

a partir de la columna *transcripcion*. Estas características permiten describir cuantitativamente el estilo, la complejidad y la coherencia del discurso, aspectos fundamentales para estudiar su relación con el rendimiento de los videos.

Las variables generadas se pueden agrupar en las siguientes categorías:

1) Métricas generales de longitud y diversidad léxica Se calcularon indicadores básicos como:

- Longitud del texto en caracteres.
- Número de palabras totales.
- Número de palabras únicas.
- Proporción de palabras únicas respecto al total de palabras.

Estas métricas permiten estimar la variedad léxica y el grado de repetición en el guion. Una mayor diversidad léxica suele asociarse con narraciones más ricas, mientras que textos extremadamente repetitivos pueden indicar discursos simples, redundantes o poco elaborados.

2) Composición de vocales y consonantes Se contabilizó el número de vocales y consonantes, así como sus proporciones relativas respecto a la longitud del texto. Aunque se trata de medidas de bajo nivel, sirven como aproximaciones a la estructura fonética del discurso y pueden relacionarse con fluidez y naturalidad en la lectura o narración.

3) Uso de signos de puntuación y estructura oracional Se extrajeron múltiples variables relacionadas con la puntuación:

- Número de puntos, comas, signos de exclamación y signos de interrogación.
- Número de oraciones (a partir de segmentación por frases).
- Promedio de palabras por oración.
- Versiones normalizadas (por longitud u oraciones) de los signos de puntuación.

Estas características permiten aproximar la estructura sintáctica y el ritmo del guion. Por ejemplo, un mayor uso de preguntas y exclamaciones puede implicar un estilo más dinámico y emocional, mientras que la longitud promedio de las oraciones se relaciona con la complejidad gramatical.

4) Emojis y densidad léxica Se contabilizó el número de emojis presentes en la transcripción, así como:

- Número de palabras que no son *stopwords* en español.
- Densidad léxica: proporción de palabras de contenido (no *stopwords*) sobre el total de palabras.

La densidad léxica es un indicador de cuánta información semántica relevante se transmite por unidad de texto. Un guion con alta densidad léxica tiende a ser más informativo, mientras que uno con baja densidad puede ser más redundante o relleno.

5) Repetitividad del discurso Se definió una métrica de repetitividad como:

$$\text{repetitividad} = 1 - \frac{\# \text{ palabras únicas}}{\# \text{ palabras totales}}$$

Esta medida toma valores cercanos a 0 cuando el texto es variado y se incrementa cuando el guion repite con frecuencia las mismas palabras. Con ella se busca capturar estilos narrativos basados en insistencia, énfasis o muletillas, típicos de algunos creadores.

Este índice busca condensar en una sola métrica la riqueza informativa y la variedad del discurso. Valores más altos indican guiones más elaborados, con menor redundancia y mayor contenido semántico.

6) Análisis lingüístico con spaCy Se utilizó un modelo de spaCy en español para obtener rasgos de nivel morfosintáctico:

- Frecuencia relativa de sustantivos.
- Frecuencia relativa de verbos.
- Frecuencia relativa de adjetivos.
- Frecuencia relativa de pronombres personales.

Estas proporciones permiten distinguir entre estilos más descriptivos (mayor uso de adjetivos), narrativos (predominio de verbos) o centrados en la primera persona (alto uso de pronombres personales). Estos patrones son relevantes para caracterizar el tipo de storytelling utilizado.

7) Embeddings y cohesión semántica Se generaron *embeddings* del texto usando un modelo de frases (*Sentence Embeddings*), lo que permite representar cada transcripción como un vector en un espacio semántico.

9) Detección de hooks narrativos Se definió un patrón de expresiones en español asociadas a ganchos (*hooks*) comunes, tales como “*por qué*”, “*cómo*”, “*secreto*”, “*increíble*”, “*impactante*”, entre otros. Se contó el número de apariciones de estos patrones en cada transcripción. Esta variable cuantifica explícitamente el uso de frases diseñadas para captar la atención al inicio o durante el video.

Features de n-gramas en español

Además de las características numéricas anteriores, se generaron variables basadas en n-gramas (secuencias de 1 a 3 palabras) utilizando un *Count-Vectorizer* configurado para español. Las decisiones de configuración incluyeron:

- Uso de *stopwords* en español para filtrar palabras funcionales poco informativas.
- Rango de n-gramas entre 1 y 3, con el fin de capturar tanto términos individuales como expresiones cortas relevantes.

- Umbrales de frecuencia mínima y máxima (`min_df` y `max_df`) para conservar únicamente aquellos n-gramas que aparecen ni demasiado poco (ruido) ni demasiado (términos triviales).

Estas columnas de n-gramas permiten al modelo identificar patrones léxicos específicos asociados a ciertos estilos, temáticas o estructuras de guion. En conjunto con las *features* continuas, proporcionan una representación rica y granular del contenido textual.

4.5. Generación de insights narrativos mediante modelos de lenguaje

Además de las características numéricas y lingüísticas derivadas directamente de las transcripciones, se incorporó un conjunto adicional de variables generadas mediante un modelo de lenguaje avanzado de OpenAI. Estas variables no forman parte del proceso de entrenamiento de los modelos predictivos, pero cumplen un rol esencial en la capa explicativa y en la interacción con el usuario a través del chatbot del sistema.

La idea central detrás de esta etapa es extraer atributos cualitativos que son difíciles o imposibles de obtener mediante técnicas tradicionales de NLP o análisis estadístico. Variables como el estilo narrativo, la emoción dominante o los elementos de retención requieren una interpretación semántica profunda del guion que supere el nivel superficial de palabras, n-gramas o estructuras sintácticas.

Estas características permiten que el sistema proporcione retroalimentación más rica y contextual al usuario. En lugar de limitarse a métricas frías (*densidad léxica*, *frecuencia de verbos*, *cohesión semántica*, etc.), el chatbot puede ofrecer análisis narrativos de alto nivel, explicaciones causales y sugerencias de mejora basadas en la dimensión cualitativa del discurso.

Para cada transcripción, el modelo de OpenAI devuelve un JSON estructurado con:

- Estilo narrativo: describe la forma general del discurso (informativo, reflexivo, anecdótico, emocional, instructivo, etc.).
- Densidad informativa: grado en el cual el guion aporta datos, contexto o contenido relevante por unidad de texto.
- Complejidad gramatical: nivel de sofisticación sintáctica y construcción de oraciones.
- Elementos de retención: técnicas narrativas detectadas (ganchos, giros, tensión, preguntas abiertas, apelaciones emocionales, etc.).
- Emoción principal: afecto dominante (sorpresa, nostalgia, tristeza, humor, indignación, etc.), útil para clasificar estilos de storytelling.
- Longitud en tokens: medida de referencia que ayuda en la normalización posterior.

Estas variables son semánticas, interpretables y orientadas al análisis cualitativo, lo cual las distingue de las métricas puramente cuantitativas generadas en etapas anteriores.

Estas características no se incorporan como *features* en los modelos supervisados por tres razones fundamentales:

1. Evitar dependencia de modelos externos: al entrenar únicamente con características derivadas del texto original, el sistema no queda atado a los posibles cambios o restricciones de la API de OpenAI.
2. Evitar contaminación del entrenamiento con información interpretativa: estas variables sintetizan conceptos de alto nivel que el modelo predictivo debería aprender de forma autónoma a partir de características objetivas.
3. Preservar la función explicativa: si estas variables se usan como insumos del modelo principal, podrían introducir sesgos o redundancias. Su propósito es narrativo y pedagógico, no predictivo.

El chatbot utiliza estas variables como base para generar recomendaciones personalizadas. Gracias a este conjunto de insights, el sistema es capaz de:

- Interpretar el estilo del guion de un creador y compararlo con el de videos virales.
- Identificar patrones narrativos incompletos o incoherentes.
- Detectar debilidades estilísticas (falta de ritmo, exceso de redundancia, poca emoción).
- Sugerir mejoras concretas adaptadas al tipo de narrativa empleada.

Al separar explícitamente la capa predictiva de la capa explicativa, el sistema logra ser robusto, interpretable y útil para fines prácticos de asesoría narrativa.

5. Procesamiento de Datos

El procesamiento de datos se diseñó para integrar información textual, numérica y visual de manera estandarizada y consistente antes de la etapa de modelación. El objetivo fue transformar las distintas modalidades en representaciones comparables y útiles para los modelos supervisados y no supervisados.

5.1. Limpieza y transformación

Se aplicaron procedimientos de limpieza orientados a garantizar la coherencia estructural del conjunto de datos sin alterar su comportamiento estadístico ni su distribución real:

- Normalización del texto: se convirtió todo a minúsculas, se eliminaron caracteres especiales y se filtró ruido como URLs, emojis aislados o tokens no textuales presentes en la descripción.
- Eliminación de variables redundantes: columnas como la longitud de caracteres, número de palabras o signos de puntuación fueron posteriormente eliminadas tras normalización para evitar multicolinealidad.

- Corrección de proporciones: variables como `palabras_no_stop`, `hooks`, `oraciones` y `signos_total` se expresaron como proporciones respecto al total de palabras o letras, lo que permite comparabilidad entre guiones cortos y largos.
- Filtrado de miniaturas: se eliminaron rutas corruptas o imágenes no disponibles con el fin de garantizar un análisis visual homogéneo.

Estas transformaciones permiten estabilizar las métricas y reducir la varianza indeseada causada por diferencias de longitud entre videos.

5.2. Ingeniería de características

La ingeniería de variables se realizó en distintos niveles, desde transformaciones básicas hasta composiciones avanzadas multimodales.

Nivel básico

Se generaron características esenciales para caracterizar el comportamiento cuantitativo y estructural:

- Longitud del guion medida en palabras, oraciones, signos y letras.
- Frecuencia absoluta y relativa de hashtags, emojis y *calls to action* (CTA).

Estas variables representan la estructura mínima necesaria para analizar la composición textual y visual de un video.

Nivel intermedio

Se incorporaron variables que capturan propiedades narrativas y lingüísticas más profundas:

- Densidad informativa: proporción de palabras con contenido semántico.
- Complejidad gramatical: proporciones de sustantivos, verbos, adjetivos y pronombres personales.
- Elementos de retención: presencia proporcional de preguntas, ganchos y signos de énfasis.
- Cohesión semántica: similitud entre párrafos mediante embeddings.
- Embeddings del guion y miniatura: representaciones vectoriales para análisis de similitud.

Estas características son fundamentales para comprender el estilo narrativo y la riqueza semántica de los guiones.

Nivel avanzado

Se generaron representaciones compuestas que integran información de varias dimensiones:

- Vector multimodal: integración del embedding del texto, el embedding de la miniatura y las métricas del video.

- Score narrativo: variable objetivo basada en una combinación ponderada de interacción (likes, comentarios y compartidos).

Este nivel constituye la entrada principal de los modelos predictivos.

5.3. Transformación y normalización de métricas de interacción

Para las variables numéricas `likes`, `comments` y `shares`, se aplicó una transformación logarítmica:

$$\text{variable_log} = \log(1 + x)$$

Esta transformación reduce la asimetría de las distribuciones, caracterizadas por colas largas propias de fenómenos virales. Posteriormente, se normalizaron a un rango 0-1:

$$\text{variable_norm} = \frac{x - \text{mín}(x)}{\text{máx}(x) - \text{mín}(x)}$$

Creación del score narrativo (`score_pct`)

Se definió un `score` compuesto como variable objetivo:

$$\text{score} = 0,5 \cdot \text{likes_norm} + 0,25 \cdot \text{comments_norm} + 0,25 \cdot \text{shares_norm}$$

y posteriormente:

$$\text{score_pct} = 100 \cdot \text{score}.$$

La ponderación otorga mayor peso a los *likes* por ser la métrica más abundante y menos ruidosa, mientras que los comentarios y compartidos complementan la interacción profunda.

El análisis de correlación mostró relaciones sólidas entre las tres métricas y el `score` final, confirmando su coherencia como variable objetivo.

5.4. Normalización de variables textuales y eliminación de redundancias

Para evitar que la longitud del texto sesgue las predicciones, varias características se transformaron a proporciones:

- Palabras no stopwords → proporción respecto al total.
- Hooks narrativos → proporción de ocurrencias por palabra.
- Frecuencia de oraciones → oraciones por palabra.
- Signos totales → signos por letra.
- Lista seleccionada de palabras frecuentes → frecuencias relativas.

Una vez normalizadas, se eliminaron las columnas brutas (`longitud`, `palabras`, `letras`, `puntos`, `comas`, etc.) para reducir dimensionalidad y prevenir redundancias.

5.5. Resultado del procesamiento

El resultado final es un conjunto de datos completamente estandarizado, con:

- variables numéricas transformadas,
- variables textuales normalizadas,
- registros visuales limpios,
- un score objetivo coherente,
- y una matriz de características lista para modelación multimodal.

Este procesamiento asegura que los modelos posteriores operen sobre datos consistentes, comparables y representativos de los patrones reales observados en TikTok.

6. Modelación

Se desarrollaron modelos tanto supervisados como no supervisados para capturar patrones relevantes:

6.1. Modelos No Supervisados

Para capturar patrones latentes en los guiones, hashtags e imágenes, se aplicaron técnicas no supervisadas basadas en embeddings de alta dimensión combinadas con algoritmos de clustering. A continuación se detalla el proceso aplicado específicamente a los guiones, el cual forma la base del análisis semántico del proyecto.

Generación robusta de embeddings para guiones

Cada transcripción fue convertida en un vector denso utilizando el modelo `text-embedding-3-large` de OpenAI. Debido a la inestabilidad ocasional de la API (errores intermitentes 429 o fallos de conexión), se implementó una función de extracción robusta con reintentos y espera exponencial. Esto asegura la generación completa del conjunto de embeddings:

- Los embeddings contienen información semántica profunda del guion.
- Poseen alta dimensionalidad, lo cual es adecuado para técnicas posteriores como HDBSCAN o UMAP.
- Se normalizaron mediante norma L2 para estabilizar la distancia entre vectores.

Análisis exploratorio con proyecciones t-SNE

Previo al clustering, los embeddings se visualizaron mediante *t-Distributed Stochastic Neighbor Embedding* (t-SNE). Este método permitió observar una

estructura no lineal donde emergen aproximadamente tres grupos principales los cuales son probablemente los tres canales que se usaron en la extracción de datos. Esta visualización sirvió como guía inicial para elegir HDBSCAN como algoritmo de clustering, dado que se apreciaban regiones con densidades muy distintas.

Clustering con HDBSCAN

El algoritmo HDBSCAN fue empleado para identificar agrupaciones naturales sin necesidad de especificar el número de clusters. Esta elección se debe a sus propiedades:

- Detecta clusters de distinta densidad.
- Maneja ruido y puntos atípicos asignando la etiqueta -1.
- Es adecuado para datos de alta dimensión como embeddings.

El modelo fue configurado con:

- `min_samples = 5`
- `min_cluster_size =` valor ajustable según experimentación
- métrica: `euclidean`
- método de selección: `eom`

Los resultados obtenidos fueron:

```
Cluster_hdbscan
-1    1572
 2     619
 0      26
 1      21
 3      18
```

Interpretación de resultados

Los valores muestran una estructura dominada por un cluster grande (619 elementos), varios clusters pequeños (26, 21 y 18) y un conjunto numeroso marcado como ruido (-1). Esto es consistente con la distribución observada en t-SNE:

- Cluster 2 representa el grupo semántico dominante, probablemente asociado a estilos narrativos frecuentes.
- Clusters 0, 1 y 3 representan nichos estilísticos específicos y poco frecuentes.
- El ruido (-1) no indica error, sino que HDBSCAN considera que esos embeddings no pertenecen a ninguna región densa; son estilos inusuales o guiones con baja coherencia semántica.

Este comportamiento es esperado en datos provenientes de TikTok, donde existe gran variabilidad narrativa y muchos videos no siguen estructuras similares entre sí.

Con ello, los embeddings de guion se convierten en una representación central para la parte no supervisada del sistema.




Figura 5: Distribución de guiones

Clustering visual de miniaturas mediante embeddings CLIP

Además del análisis semántico de los guiones, se generaron embeddings visuales para todas las miniaturas utilizando el modelo CLIP. Este modelo permite representar imágenes en un espacio vectorial donde proximidad implica similitud visual. Dado que los estilos gráficos varían significativamente entre canales, se decidió entrenar un modelo de clustering independiente para cada creador.

Extracción de embeddings por canal Cada miniatura fue procesada en su respectivo canal, generando embeddings de dimensión fija. Se verificó que las dimensiones fueran consistentes dentro de cada canal, asegurando la estabilidad del proceso:

- Cada canal produjo embeddings con la misma dimensión.
- Se eliminaron embeddings nulos o corruptos.
- Se utilizó normalización L2 para estabilizar la distancia euclidiana.

Exploración visual con t-SNE Para cada canal se aplicó t-SNE con el fin de visualizar la estructura latente de los embeddings. Las observaciones fueron:

- En el canal faridieck se aprecian tres conglomerados principales, aunque con dispersión interna.
- En los canales hernanmartinezl y kurz_gesagt la estructura visual es menos clara, con mayor superposición entre miniaturas.
- Las diferencias se deben al estilo gráfico de cada creador: algunos mantienen una línea visual más uniforme, mientras que otros exploran diversos estilos.

Clustering con HDBSCAN por canal Siguiendo la metodología aplicada a los guiones, se utilizó HDBSCAN para detectar agrupaciones visuales dentro de cada canal:




Figura 6: Distribución de imagenes




Figura 7: Distribución de imagenes




Figura 8: Distribución de imagenes

HDBSCAN(min_samples = 5, min_cluster_size = 30, metric = euclidean).

Esto permite capturar regiones densas en el espacio de embeddings sin forzar un número fijo de clusters. Los resultados obtenidos fueron los siguientes:

Canal faridieck (7 clusters)

```
Cluster_hdbscan
-1    1248
 4     440
 2     42
 5     15
 0     14
 3      9
 1      8
```

Canal hernanmartinezl (3 clusters)

```
Cluster_hdbscan
-1    119
 0     12
 1      2
```

Canal kurz_gesagt (4 clusters)

```
Cluster_hdbscan
-1    338
 1     57
 2      5
 0      4
```

Interpretación global Los resultados permiten extraer varias conclusiones significativas:

- El canal faridieck presenta alta variabilidad visual: 7 clusters + un gran conjunto de ruido indican un estilo gráfico diverso y no homogéneo.
- El canal hernanmartinezl tiene muy poca variabilidad: solo 3 clusters, con uno muy dominante. Sugiere un estilo visual repetitivo o muy estable.
- kurz_gesagt, aunque presenta una identidad visual clara, muestra 4 clusters definidos, lo cual se corresponde con su mezcla de estilos (fondos planos, ilustraciones complejas, escenas temáticas).
- El alto número de puntos etiquetados como -1 no indica error: refleja estilos individuales o miniaturas atípicas que no pertenecen a ninguna región densa. Esto es esperado en contenido de redes sociales.




Figura 9: Ejemplo de cluster del canal de Faridieck




Figura 10: Ejemplo de cluster del canal de hernanmartinezi

Utilidad dentro del sistema Los clusters visuales se integran a la plataforma de forma que el sistema puede sugerir miniaturas similares basándose en el cluster del usuario.

Visualización de ejemplos representativos por cluster

Para complementar el análisis, se seleccionaron imágenes representativas de los principales clusters de cada canal. Estas visualizaciones permiten corroborar la coherencia visual interna de los grupos.

A continuación se reservan las figuras donde se insertarán las miniaturas ejemplo:

6.2. Modelos Supervisados

Además del análisis no supervisado, se entrenaron modelos supervisados con el objetivo de predecir el *score narrativo* previamente definido. Este score sintetiza el desempeño del video en métricas de interacción y constituye la variable objetivo para las tareas de clasificación y regresión.



Figura 11: Ejemplo de cluster del canal de kurz_gesagt

Definición del problema supervisado

El análisis supervisado se abordó en dos niveles:

1. Clasificación en categorías de viralidad Se definieron tres clases exclusivas:
 - Clase 0: videos de *bajo rendimiento* (percentil ≤ 10).
 - Clase 1: videos de *rendimiento normal* (percentiles 10-90).
 - Clase 2: videos *virales* (percentil ≥ 90).
2. Regresión del score narrativo Predicción directa del valor continuo del score (`score_pct`).

Ambas tareas complementan usos distintos dentro del sistema: la clasificación permite identificar segmentos bien diferenciados, mientras que la regresión otorga un valor numérico interpretable en términos absolutos.

Asignación de clases y balanceo

La distribución natural del score es altamente asimétrica; la mayoría de videos se encuentran en la categoría central y solo una minoría corresponde a casos extremos. Se utilizó:

$$\text{Clase 0} = \{x \mid x \leq q_{0,10}\}, \quad \text{Clase 2} = \{x \mid x \geq q_{0,90}\}, \quad \text{Clase 1} = \text{resto}.$$

La distribución obtenida fue:

- 79.96 % clase normal,
- 10.02 % clase baja,
- 10.02 % clase viral.

Para controlar el desbalance, se aplicó *class weighting* mediante:

$$w_c = \frac{N}{K \cdot N_c},$$

donde N es el número total de muestras, $K = 3$ clases, y N_c el número de ejemplos en la clase c .

Modelo de clasificación

Se entrenó una red neuronal multicapa con las siguientes características:

- Entrada: vector denso de características normalizadas.
- Capas ocultas:
 - Dense(256, activation=`swish`) + Dropout(0.25)
 - Dense(128, activation=`swish`) + Dropout(0.20)
 - Dense(64, activation=`swish`)
- Capa de salida: Dense(3, activation=`softmax`).

- Función de pérdida: `categorical_crossentropy`.
- Optimizador: Adam (1e-3).
- Métrica principal: `accuracy`.

Las funciones de activación *swish* se seleccionaron debido a su buen desempeño en tareas donde se requiere capturar relaciones no lineales suaves, superando a funciones tradicionales como ReLU en estabilidad y suavidad del gradiente.

Durante el entrenamiento (50 épocas, batch size=16), el modelo alcanzó:

$$\text{Accuracy} = 0,7581.$$

Este valor es notable considerando el desbalance original y la alta variabilidad del contenido. El uso de *class weighting* permitió que el modelo no convergiera trivialmente hacia la clase mayoritaria.

Modelo de regresión

Además del clasificador, se entrenó un modelo regresivo destinado a predecir el score narrativo en su escala continua (0-100). La arquitectura utilizada fue similar:

- Dense(256, swish) + Dropout(0.25)
- Dense(128, swish) + Dropout(0.20)
- Dense(64, swish)
- Salida: Dense(1, activación lineal)

Con las siguientes configuraciones:

- Pérdida: `mse`
- Métrica: `mae`
- Optimizador: Adam(1e-3)

El uso de pérdida MSE se justificó al buscar penalizar más fuertemente predicciones alejadas del valor real. Las curvas de entrenamiento mostraron convergencia estable y sin sobreajuste significativo debido al uso de *dropout*.

Resultados para el grupo viral El rango de valores reales fue:

$$78,09 \leq x \leq 95,47 \quad (\Delta = 17,38).$$

Los resultados del modelo fueron:

- MAE: 3.5290
- MSE: 21.1030
- RMSE: 4.5938
- MAPE: 4.09 %

Estos valores reflejan un excelente desempeño, especialmente considerando el rango estrecho del grupo. El error relativo se mantiene por debajo del 5 %, adecuado para una escala de 0-100.

Resultados para el grupo de bajo rendimiento Rango observado:

$$7,81 \leq x \leq 28,60 \quad (\Delta = 20,79).$$

- **MAE:** 6.1043
- **MSE:** 50.5811
- **RMSE:** 7.1120
- **MAPE:** 32.76 %

Este grupo presenta mayor variabilidad interna y menor cantidad de ejemplos, lo que explica el MAPE elevado. Además, los valores cercanos a cero amplifican el error porcentual.

Resultados para el grupo normal Dado que el grupo normal cubre aproximadamente:

$$28,6 \leq x \leq 78,1 \quad (\Delta \approx 49,5),$$

el rango es más del doble que el de los grupos extremos. El modelo obtuvo:

- **MAE:** 8.6981
- **MSE:** 129.4874
- **RMSE:** 11.3793
- **MAPE:** 15.87 %

El error es mayor debido a:

- La amplitud del rango del grupo (el más grande en todo el dataset).
- La heterogeneidad narrativa típica de los videos promedio.

Conclusión La regresión especializada por nivel de viralidad demuestra ser una estrategia efectiva:

- Permite reducir drásticamente el error en extremos donde el patrón es más estable (grupo viral).
- Mitiga el impacto del desbalance de datos.
- Facilita interpretabilidad y consistencia al chatbot, que puede usar el modelo específico según el nivel asignado.

En conjunto, los tres modelos capturan de manera precisa la relación entre las características narrativas y visuales del video y su rendimiento final.

7. Resolución del Problema e Implementación de la Plataforma

Además del desarrollo de modelos de análisis y predicción, se implementó una plataforma web interactiva utilizando *Streamlit*, con el objetivo de acercar las capacidades del sistema a usuarios finales (creadores de contenido, analistas o interesados en narrativa audiovisual). Esta interfaz permite explorar los modelos entrenados de forma intuitiva, recibiendo retroalimentación en tiempo real a partir de guiones y miniaturas.




Figura 12: Página de inicio

7.1. Arquitectura general de la aplicación

La aplicación se estructura en múltiples páginas accesibles mediante una barra de navegación (*navbar*). Cada página está diseñada para cubrir una parte del flujo de trabajo de un creador de contenido:

- Carga de insumos (guión y miniatura).
- Análisis automático del contenido.
- Recomendaciones narrativas y visuales.
- Exploración de ejemplos similares.
- Herramientas adicionales (audio, hashtags, búsqueda de videos).

La lógica de backend integra los modelos de:

- Clasificación de viralidad.
- Regresión general y regresiones especializadas por nivel de viralidad.
- Embeddings textuales y visuales (guiones y miniaturas).
- Chatbot explicativo basado en LLM.

7.2. Páginas principales de la plataforma

Página de inicio

La página de inicio presenta una explicación general del proyecto, su objetivo y el flujo de uso sugerido. El usuario puede conocer:

- Qué es el *score narrativo* y cómo se interpreta.
- Qué tipo de entradas se esperan (guiones, miniaturas).
- Qué tipo de salidas ofrece el sistema (puntuaciones, feedback, ejemplos).




Figura 13: Página de carga de archivos




Figura 14: Página de resultados

Página de carga y análisis de inputs

En esta página el usuario puede cargar:


A partir de estos insumos, la plataforma:

- Calcula el *score narrativo* utilizando el modelo de clasificación y el regresor correspondiente a la clase asignada (bajo, normal, viral).
- Muestra el nivel de viralidad estimado.
- Genera análisis textuales (densidad, hooks, estilo narrativo, etc.).
- Encuentra y despliega los 5 videos más similares en guión y miniatura.

Página del chatbot explicativo

Esta sección integra un chatbot especializado en narrativa y retención, alimentado por:

- Las características numéricas del guión.






Figura 18: Página de exploración de videos




Figura 19: Página de vista de video

Página de búsqueda y dashboards de videos

Finalmente, se incluye una página de exploración de videos ya existentes en el dataset:

- Búsqueda por texto: el usuario ingresa una frase y el sistema encuentra los videos con guiones más similares mediante embeddings.
- Navegación por miniaturas y descripciones: se pueden explorar videos por su imagen y texto asociado.
- Dashboard individual: para cada video se muestra un panel con sus métricas, score narrativo, cluster visual, cluster narrativo y ejemplos similares.

En todos los casos, se muestran los 5 videos más parecidos tanto a nivel de guion como de miniatura, lo que facilita la comparación y la inspiración.

7.3. Relación entre los modelos y la plataforma

La integración entre modelos y frontend permite cerrar el ciclo completo:

1. El usuario ingresa sus insumos (guión, miniatura).
2. El sistema genera características y aplica el modelo supervisado y los clusters relevantes.
3. La plataforma muestra:
 - El nivel de viralidad estimado con score.
 - Ejemplos similares.
 - Recomendaciones narrativas y de hashtags.
 - Una previsualización en audio del guión.
4. El usuario puede iterar sobre su guión hasta mejorar sus resultados.

De esta manera, la plataforma no solo ilustra el funcionamiento de los modelos desarrollados, sino que los convierte en una herramienta práctica para mejorar la calidad narrativa de contenidos en TikTok.

8. Conclusiones

El presente proyecto demostró que es posible analizar y predecir el rendimiento de videos de TikTok mediante un enfoque multimodal que integra procesamiento de lenguaje natural, visión por computadora y técnicas de aprendizaje automático. La combinación de embeddings semánticos, análisis lingüístico avanzado, clustering no supervisado y modelos supervisados permitió capturar relaciones complejas entre el contenido narrativo, las miniaturas y el nivel de interacción obtenido por los videos.

Los resultados muestran que los guiones con estructuras narrativas claras, mayor densidad informativa y presencia de elementos de retención tienden a asociarse con mejores métricas de rendimiento. De manera similar, las miniaturas con estilos visuales consistentes y patrones recurrentes dentro de cada canal tienden a conformar clusters visuales más definidos, lo que sugiere la existencia de identidades gráficas asociadas al éxito.

La división del problema de regresión por niveles de viralidad permitió obtener modelos más estables y precisos en rangos reducidos, especialmente en los extremos (bajo y viral). La aproximación especializada superó a un único modelo global, resaltando la importancia de capturar patrones específicos de cada segmento. Asimismo, el clasificador de viralidad alcanzó un desempeño competitivo pese al desbalance natural de los datos.

La plataforma desarrollada en Streamlit representa un aporte práctico significativo: integra todos los modelos en una experiencia interactiva capaz de ofrecer retroalimentación inmediata y comprensible para creadores de contenido. A través del chatbot, las recomendaciones técnicas se traducen en sugerencias narrativas, estilísticas y visuales que facilitan la mejora iterativa de los guiones.

Limitaciones

Aunque los resultados fueron satisfactorios, el proyecto presenta algunas limitaciones relevantes:

- El dataset proviene de un número limitado de canales, lo que podría restringir la generalización del modelo a otros estilos narrativos o nichos.
- La transcripción de TikTok puede contener errores de reconocimiento de voz que impactan en los embeddings y las métricas lingüísticas.
- El modelo supervisado se basa en métricas públicas (likes, comentarios, compartidos), lo que no captura variables internas de TikTok como tiempo de retención o CTR real.
- Las miniaturas procesadas varían en calidad, resolución y formato, afectando la consistencia de los embeddings visuales.

Líneas de trabajo futuro

A partir del desarrollo actual, existen múltiples caminos para extender y mejorar el sistema:

- Integrar datos adicionales como información demográfica de audiencia, tasas reales de retención y tiempos de visualización.
- Entrenar modelos narrativos específicos para español, con ajuste fino en dominios como storytelling educativo, humorístico o divulgativo.
- Implementar técnicas más avanzadas de visión por computadora, como modelos Vision Transformer (ViT), CLIP-SigLIP o DINOv2 para mejorar la segmentación visual.
- Explorar modelos generativos para sugerir reescrituras completas de guiones o alternativas de miniaturas.
- Incluir un sistema de evaluación A/B dentro de la plataforma para permitir al usuario comparar distintas versiones de su guión.

Reflexión final

En conjunto, los resultados confirman que el uso de inteligencia artificial multimodal ofrece un marco robusto para analizar contenido de video corto. Este tipo de herramientas tiene el potencial de convertirse en asistentes creativos fundamentales para mejorar la calidad y la efectividad narrativa en plataformas como TikTok. El proyecto sienta las bases de un sistema de apoyo a creadores que podría expandirse hacia aplicaciones reales en industrias de contenido, marketing digital y producción audiovisual.

9. Referencias

- Brown, T., et al. (2020). *Language Models are Few-Shot Learners*. NeurIPS.

- Devlin, J., Chang, M., Lee, K., & Toutanova, K. (2018). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. arXiv:1810.04805.
- OpenAI. (2024). *Text Embeddings and Multimodal Models*. OpenAI Technical Reports.
- Radford, A., Kim, J., Hallacy, C., et al. (2021). *Learning Transferable Visual Models From Natural Language Supervision*. ICML.
- TikTok Research. (2023). *Understanding User Engagement in Short-Form Video Platforms*. ByteDance Research Reports.